*Ciudad de Buenos Aires, Marzo de 2026*

.UBAfiuba
FACULTAD DE INGENIERÍA

# Predicción de series de tiempo aplicado al trading de criptomonedas usando la arquitectura de Transformers

Martin Leonardo Centurion

**Carrera de Especialización en Inteligencia Artificial**

**Director:** Camilo Argoty

**Jurados:**

Jurado 1 (pertenencia)
Jurado 2 (pertenencia)
Jurado 3 (pertenencia)

# *Resumen*

Este trabajo se enfoca en el estudio y la aplicación de la arquitectura Transformer para la predicción de series de tiempo financieras, específicamente en el contexto de un sistema de trading de criptomonedas. Se desarrolla un modelo Transformer capaz de procesar indicadores técnicos para optimizar decisiones de compra y venta en el par BTC/USDT. La importancia de este enfoque radica en la capacidad del Transformer para capturar dependencias a largo plazo en datos secuenciales, lo que representa una ventaja comparativa en un mercado estocástico y ruidoso. El lector encontrará una revisión del estado del arte, la implementación del modelo, su evaluación frente a una estrategia de "comprar y esperar", y un análisis de los desafíos de los datos financieros. Se aplican conceptos de aprendizaje profundo, redes neuronales y análisis de series de tiempo para la optimización de estrategias algorítmicas.

# Índice general

**Resumen** I

**1. Introducción general** 1
1.1. Motivación . . . 1
1.2. Descripción de la problemática . . . 2
1.3. Estado del arte . . . 3
1.4. El desafío de los datos financieros . . . 3
1.5. Objetivos, alcance y requerimientos . . . 4

**2. Introducción específica** 7
2.1. Trading . . . 7
2.2. Análisis técnico . . . 8
2.3. Aprendizaje supervisado . . . 8
2.4. Optimización de hiperparámetros . . . 9
2.5. Ensambles . . . 9
2.6. Transformers . . . 9
2.7. Metodologías de evaluación y gestión de riesgo . . . 10
2.7.1. Backtesting . . . 10
2.7.2. Validación cruzada (Cross Validation) . . . 10
2.7.3. Dimensionamiento de la apuesta (Bet sizing) . . . 10
2.7.4. Ratio de sharpe y sus variantes . . . 11

**3. Diseño e implementación** 13
3.1. Conjunto de datos y preprocesamiento . . . 13
3.1.1. Conjunto de datos . . . 13
3.1.2. Estrategias de preprocesamiento . . . 13
3.1.3. Ingeniería de características y análisis de importancia . . . 14
3.1.4. Arquitectura del modelo . . . 15
3.2. Estrategias de Referencia (Baselines) . . . 15
3.2.1. Técnicas de etiquetado . . . 17

**4. Ensayos y resultados** 19
4.1. Pruebas funcionales del hardware . . . 19

**5. Conclusiones** 21
5.1. Conclusiones generales . . . 21
5.2. Próximos pasos . . . 21

**Bibliografía** 23

# Índice de figuras

1.1. Evolución del precio del par BTC/USDT en el período analizado.[1] 2
1.2. Diagrama conceptual de la arquitectura del sistema de trading. . . 4

# Índice de tablas

# Capítulo 1

# Introducción general

Este capítulo presenta una introducción al problema de la predicción de series de tiempo en el dominio financiero y su aplicación concreta en el desarrollo de un sistema de trading para el mercado de criptomonedas. Se describen el contexto y la motivación que impulsan la elección de la arquitectura Transformer como herramienta principal para el análisis. Además, se detalla la problemática del trading algorítmico, se revisa el estado del arte en la materia, se exponen los desafíos inherentes al manejo de datos financieros y, finalmente, se definen con claridad los objetivos, el alcance y los requerimientos que guiarán este trabajo.

## 1.1. Motivación

La elección de este trabajo se fundamenta en la confluencia de dos pilares de gran relevancia actual: la complejidad del problema a resolver y la sofisticación de las herramientas seleccionadas para abordarlo. El trading de activos financieros es una actividad que busca generar rentabilidad a partir de las fluctuaciones de los precios en el mercado [1], lo que representa un desafío intelectual y técnico de alta complejidad debido a la naturaleza inherentemente ruidosa y dinámica de los mercados.

Gran parte de las decisiones en este campo se apoyan en el análisis técnico, que consiste en la interpretación de un amplio abanico de indicadores derivados de la actividad histórica de precios y volúmenes [2]. La combinación manual de estos indicadores para tomar decisiones de compra o venta requiere una experiencia considerable y una intuición desarrollada a lo largo de años. Además, este enfoque manual es difícil de escalar para analizar de manera simultánea la vasta cantidad de información disponible, lo que hace atractiva la idea de desarrollar un modelo de machine learning que pueda procesar y ponderar un gran número de indicadores técnicos para optimizar las decisiones de manera sistemática y objetiva.

Por otro lado, la arquitectura Transformer, gracias a su innovador mecanismo de autoatención, ha demostrado una capacidad excepcional para modelar dependencias a largo plazo en datos secuenciales y se ha consolidado como el estado del arte en campos como el procesamiento de lenguaje natural. Esta cualidad la convierte en una candidata ideal para el análisis de series de tiempo financieras [3], en el que eventos pasados, incluso lejanos en el tiempo, pueden tener una influencia significativa en el comportamiento futuro de los precios. A diferencia de los modelos recurrentes tradicionales, como las redes LSTM, que pueden tener dificultades para mantener información a través de secuencias muy largas, el

Transformer puede teóricamente capturar relaciones entre puntos distantes en el tiempo de manera más efectiva. Esto permitiría, por ejemplo, identificar patrones complejos que ayuden a evitar operaciones que parecen rentables a corto plazo pero que conllevan un alto riesgo, o, por el contrario, aprovechar oportunidades de baja rentabilidad pero con un riesgo casi nulo.

## 1.2. Descripción de la problemática

En la comercialización de activos financieros, el objetivo fundamental es generar una ganancia mediante la compra a un precio bajo y la venta a un precio más alto. Este principio, aunque simple en apariencia, sería trivial si se pudiera predecir el futuro de los precios con certeza. Sin embargo, la realidad de los mercados es que son sistemas inherentemente estocásticos y no lineales [4], como se puede apreciar en la volatilidad del precio de Bitcoin en la figura 1.1. Las personas que operan en estos mercados pueden clasificarse a grandes rasgos en dos categorías: los analistas fundamentales, que basan sus decisiones en el valor intrínseco de los activos y factores macroeconómicos, y los analistas técnicos, que se centran en el estudio de patrones históricos de precios y volúmenes para predecir movimientos futuros [5].

FIGURA 1.1. Evolución del precio del par BTC/USDT en el período analizado.[1]

Este trabajo se enmarca estrictamente en el dominio del análisis técnico, con el propósito de desarrollar un sistema de trading algorítmico diseñado para operar de manera autónoma en el mercado spot de criptomonedas. Específicamente, se trabajará con el par BTC/USDT, uno de los más líquidos y volátiles del mercado. El objetivo del sistema es decidir, en intervalos de tiempo discretos, si es más conveniente mantener la posición en Bitcoin (BTC), con la expectativa de que su valor aumente con respecto al Tether (USDT), o si es preferible mantener la posición en USDT, un stablecoin anclado al valor del dólar estadounidense, como una forma de protegerse ante una posible caída en el precio del Bitcoin. Esta decisión binaria representa un problema de clasificación que es ideal para ser abordado con técnicas de deep learning.

[1] Gráfico obtenido de la plataforma de trading Binance.

## 1.3. Estado del arte

El uso de inteligencia artificial para el trading ha ganado un protagonismo creciente en las últimas dos décadas y ha evolucionado desde modelos estadísticos tradicionales hasta complejas arquitecturas de redes neuronales [6]. Tanto en el ámbito comercial como en el académico, se ha reconocido el potencial de la IA para automatizar y mejorar la toma de decisiones. Empresas como AutoTrade.AI o Finbrain Technologies ya ofrecen servicios de trading automático basados en señales predictivas generadas por modelos de IA, dirigidos tanto a inversores minoristas como institucionales.

En paralelo, el ámbito académico ha explorado extensamente el uso de machine learning para la optimización de portafolios y la predicción de mercados [7]. Los primeros enfoques se basaron en modelos como máquinas de soporte vectorial (*SVM*) y bosques aleatorios (random forests), que demostraron cierta capacidad predictiva. Con la llegada del deep learning, las redes neuronales recurrentes (*RNN*) y, en particular, las redes con memoria a corto y largo plazo (*LSTM*), se convirtieron en el estándar para el análisis de series de tiempo. Sin embargo, en los últimos años, la arquitectura Transformer ha emergido como una alternativa superior en muchos dominios secuenciales.

A pesar de los avances, muchos de estos enfoques se enfrentan a un obstáculo teórico fundamental: la Hipótesis de los Mercados Eficientes (EMH) [5]. Esta hipótesis, en su forma débil, sugiere que toda la información pasada ya está reflejada en el precio actual de los activos, lo que haría inútil cualquier intento de obtener ganancias extraordinarias si se basan únicamente en el análisis técnico. Aunque la validez de la EMH para el mercado de criptomonedas es un tema de intenso debate, se observa que la eficiencia del mercado tiende a aumentar a medida que este madura, lo que representa un desafío constante para el desarrollo de nuevos modelos predictivos.

## 1.4. El desafío de los datos financieros

La aplicación de técnicas de machine learning a los mercados financieros presenta un conjunto de desafíos únicos que no se encuentran comúnmente en otros dominios:

- Bajo ratio señal ruido: los movimientos de precios de los activos son inherentemente ruidosos. La señal predictiva, que representa la información útil para la predicción, a menudo se encuentra oculta bajo una gran cantidad de fluctuaciones aleatorias o "ruido". Esto incrementa significativamente el riesgo de sobreajuste (overfitting), y el modelo aprende a memorizar el ruido de los datos de entrenamiento en lugar de la señal subyacente, lo que resulta en un bajo rendimiento en datos no vistos [8].
- No estacionariedad: las propiedades estadísticas de las series de tiempo financieras, como la media y la varianza, cambian con el tiempo. Esto se debe a que los mercados están influenciados por factores externos cambiantes, como cambios en la regulaciónnómicas o avances tecnológicos. Como resultado, los patrones aprendidos en un período de tiempo pueden no ser válidos en el futuro, lo que degrada el rendimiento del modelo a lo largo del tiempo [8].

- Costos de transacción: en un entorno de trading real, cada operación de compra o venta incurre en costos, como comisiones de la plataforma y deslizamientos (slippage). Operar con alta frecuencia, aunque teóricamente podría permitir capturar más oportunidades de mercado, puede llevar a que las ganancias generadas por el modelo sean completamente consumidas por los costos transaccionales, lo que resulta en una pérdida neta [8].

Estos factores subrayan la necesidad de un diseño metodológico riguroso y específico para el dominio financiero, que vaya más allá de la simple aplicación de algoritmos estándar y considere estas particularidades.

## 1.5. Objetivos, alcance y requerimientos

El objetivo principal de este trabajo es estudiar y evaluar rigurosamente el desempeño de la arquitectura Transformer en la predicción de series de tiempo para su aplicación en un sistema de trading de criptomonedas en el mercado spot de la plataforma Binance. Para alcanzar este objetivo principal, se han definido los

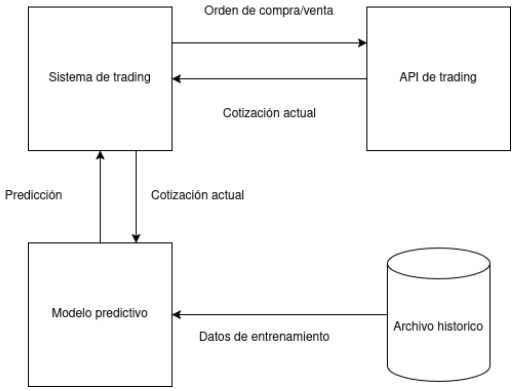


FIGURA 1.2. Diagrama conceptual de la arquitectura del sistema de trading.

siguientes objetivos específicos:

1. Realizar una revisión exhaustiva del estado del arte sobre la aplicación de modelos de deep learning (y en particular la arquitectura Transformer y sus variantes) a la predicción de series de tiempo financieras.

2. Implementar un modelo Transformer que utilice un conjunto de indicadores técnicos como datos de entrada para estimar si es óptimo posicionarse en BTC o en USDT en el par BTC/USDT durante el siguiente intervalo de tiempo.

3. Comparar el desempeño del modelo propuesto con una estrategia de referencia pasiva de "comprar y esperar" (buy and hold). El objetivo final no es maximizar la cantidad de USDT acumulado, sino la cantidad de BTC, lo cual implica una estrategia de gestión de riesgo a largo plazo.

4. Probar distintas técnicas y configuraciones del modelo, como diferentes variantes de la arquitectura Transformer, distintos conjuntos de características de entrada y optimizaciones de hiperparámetros, para decidir el modelo final con el mejor desempeño.

El alcance de este trabajo se centra en la implementación y evaluación de un sistema de trading algorítmico, cuya arquitectura conceptual se ilustra en la figura 1.2. Este sistema incluye su operación simulada en un entorno de backtesting robusto [8], que utiliza datos históricos fuera de la muestra para evitar el sesgo de anticipación (lookahead bias), así como la capacidad de operar en tiempo real a través de la API de Binance. Adicionalmente, se buscará determinar una frecuencia de operación que optimice el equilibrio entre la disponibilidad de datos para el entrenamiento del modelo y el impacto de los costos transaccionales en la rentabilidad final.

# Capítulo 2

# Introducción específica

En este capítulo se introducen temas con mayor profundidad que en el capítulo previo y se cubren aspectos fundamentales de trading, análisis técnico y conceptos clave de aprendizaje automático, indispensables para comprender el desarrollo y los resultados del trabajo.

## 2.1. Trading

El trading es la actividad de comprar y vender activos en mercados financieros con el objetivo de obtener ganancias a corto plazo, y se diferencia de la inversión tradicional por la duración de las posiciones. Mientras que un inversor mantiene posiciones a largo plazo, un trader busca aprovechar tendencias de menor duración [1].

El objetivo principal de un trader es generar ganancias al comprar a precios bajos y vender a precios más altos. Los activos comercializados pueden ser acciones, bonos, divisas, commodities (como oro o petróleo) y derivados (como futuros u opciones) [9].

Los traders se pueden clasificar según el tipo de estrategia que emplean [10]:

- Scalping: implica la compra y venta de instrumentos financieros en lapsos muy breves (segundos a minutos) para generar pequeñas ganancias en cada operación.
- trading diario: la duración de las posiciones va desde minutos a horas, con múltiples operaciones abiertas simultáneamente.
- Swing trading: las operaciones pueden durar días o semanas. Se considera menos riesgosa que las anteriores debido a la mayor disponibilidad de tiempo para tomar decisiones.
- trading de eventos: busca beneficiarse de movimientos rápidos de precio causados por eventos económicos o financieros específicos (adquisiciones de empresas, publicaciones de ganancias, decisiones regulatorias, etc.).

Otra clasificación se basa en el tipo de información utilizada y diferencia a los analistas fundamentales y a los analistas técnicos, ya introducidos en la sección 1.2.

## 2.2. Análisis técnico

El análisis técnico es una metodología para pronosticar las direcciones futuras de los precios mediante el estudio de datos históricos del mercado, principalmente el precio y el volumen operado [2].

Esta metodología fue formalizada por Charles Dow a fines del siglo XIX [11] y ha sido enriquecida por numerosos investigadores. Actualmente, el análisis técnico incluye cientos de patrones y señales [12].

La teoría de Dow establece seis puntos principales [13]:

- El precio lo descuenta todo: la información disponible sobre un activo ya se encuentra incorporada en su cotización bursátil.
- Las tres tendencias del mercado: el mercado se mueve en tendencias alcistas o bajistas. Se distinguen tres tipos de tendencias:
  - Tendencias primarias: son las principales y duran de uno a tres años.
  - Tendencias secundarias o intermedias: van en dirección contraria a las primarias, pero son de menor tamaño ("correcciones").
  - Tendencias terciarias o menores: van en dirección contraria a las secundarias y son de menor duración.
- Las tres fases de las tendencias primarias: las tendencias alcistas tienen fases de "acumulación", "participación pública" y "euforia"; las bajistas tienen fases de "distribución", "participación pública" y "pánico".
- Principio de confirmación: para confirmar una tendencia del mercado (alcista o bajista), los índices de industrias y de transportes deben tener la misma tendencia.
- El volumen bursátil debe confirmar la tendencia: si la tendencia es al alza, el volumen debe aumentar con el precio y disminuir cuando baja. Si la tendencia es a la baja, el volumen debe aumentar cuando el precio baja y disminuir cuando sube.
- La tendencia se mantiene vigente hasta que se demuestre lo contrario: una tendencia se considera válida hasta que se confirma una tendencia opuesta.

## 2.3. Aprendizaje supervisado

El aprendizaje automático (machine learning) se clasifica comúnmente en aprendizaje supervisado, no supervisado y por refuerzo. El aprendizaje supervisado se basa en el uso de datos etiquetados para entrenar un modelo que aprenda a predecir una salida a partir de una entrada [14].

Esta técnica se divide en dos categorías principales:

- Clasificación: el modelo predice una categoría discreta o una etiqueta. Por ejemplo, predecir si un activo subirá o bajará en el periodo siguiente.
- Regresión: el modelo predice un valor numérico continuo. Por ejemplo, predecir el precio futuro de un activo financiero .

Para este trabajo, se optó por un enfoque de clasificación, en el que el modelo predice la dirección del movimiento del precio (subida o bajada) en lugar de la magnitud exacta.

## 2.4. Optimización de hiperparámetros

Es fundamental distinguir entre los parámetros de un modelo y sus hiperparámetros. Los parámetros son valores aprendidos por el modelo durante el entrenamiento a partir de los datos (por ejemplo, los pesos en una red neuronal o la pendiente en una regresión lineal). Los hiperparámetros, en cambio, son configuraciones que se definen antes del entrenamiento y no se modifican durante este proceso (por ejemplo, la tasa de aprendizaje o la profundidad de un árbol de decisión) [14].

El rendimiento de un modelo depende tanto de sus parámetros como de sus hiperparámetros. La optimización de hiperparámetros es el proceso de buscar la combinación de valores de hiperparámetros que resulta en el mejor desempeño del modelo. Esto a menudo implica entrenar múltiples modelos con diferentes combinaciones y seleccionar el que ofrezca los mejores resultados en un conjunto de validación [14]. Aunque la optimización de hiperparámetros es conveniente, puede ser computacionalmente intensiva para modelos complejos, como las redes neuronales profundas o los modelos basados en aprendizaje por refuerzo.

## 2.5. Ensambles

En el ámbito del aprendizaje automático, los ensambles son el resultado de combinar múltiples modelos entrenados individualmente para obtener un desempeño general superior al que se lograría con un solo modelo [15]. La idea es que los puntos débiles de un modelo puedan ser compensados por los puntos fuertes de otros, lo que mejora la robustez y la precisión de las predicciones. Existen diferentes técnicas de ensamble, como bagging y boosting, que combinan los modelos de distintas maneras [15].

## 2.6. Transformers

La arquitectura Transformer, introducida por Vaswani et al. [16], revolucionó el procesamiento de secuencias, especialmente en el ámbito del procesamiento del lenguaje natural (PLN), y ha demostrado ser altamente efectiva también en el análisis de series de tiempo. A diferencia de los modelos recurrentes o convolucionales tradicionales, los Transformers se basan completamente en mecanismos de auto atención (self attention), lo que les permite modelar dependencias de largo alcance en las secuencias de entrada de manera más eficiente y paralelizable.

Los componentes clave de un Transformer incluyen:

- Mecanismo de auto atención (Self Attention): permite al modelo ponderar la importancia de diferentes partes de la secuencia de entrada al procesar cada elemento. Cada token (o punto en la serie de tiempo) interactúa con todos los demás tokens y calcula una puntuación de atención que determina cuánto debe enfocarse en cada uno.

- Codificación posicional (Positional Encoding): dado que el mecanismo de atención no es sensible al orden de los elementos en una secuencia, se añade una codificación posicional a las incrustaciones de entrada para inyectar información sobre la posición relativa de cada elemento.
- Bloques encoder decoder: la arquitectura original consiste en un encoder y un decoder. El encoder procesa la secuencia de entrada para crear una representación contextualizada, y el decoder utiliza esta representación para generar la secuencia de salida. En aplicaciones de series de tiempo predictivas, a menudo se utiliza solo la parte del encoder o variaciones específicas para la tarea.

La capacidad de los Transformers para capturar relaciones complejas y no lineales entre puntos distantes en el tiempo los convierte en una herramienta potente para la predicción de series de tiempo financieras, en el que los eventos pasados pueden tener un impacto significativo y no trivial en los movimientos futuros del mercado.

## 2.7. Metodologías de evaluación y gestión de riesgo

### 2.7.1. Backtesting

El backtesting es el pilar fundamental para evaluar una estrategia de trading. Consiste en simular el comportamiento de la estrategia al utilizar datos históricos para estimar cómo se habría desempeñado en el pasado. Un backtesting riguroso debe evitar el sesgo de retrospección (look ahead bias) y asegurar que las decisiones del modelo en un punto del tiempo se basen únicamente en información disponible hasta ese momento [8].

### 2.7.2. Validación cruzada (Cross Validation)

La validación cruzada es una técnica para evaluar la capacidad de generalización de un modelo y prevenir el sobreajuste. Sin embargo, la validación cruzada estándar (como K-Fold) no es adecuada para series de tiempo debido a la dependencia temporal de los datos. En su lugar, se utilizan métodos especializados:

- Purged K-Fold Cross-Validation: esta técnica introduce dos modificaciones clave. Primero, se inserta un embargo o período de exclusión después de cada conjunto de validación para evitar que la información futura se filtre al conjunto de entrenamiento. Segundo, purgan del conjunto de entrenamiento aquellas observaciones cuya etiqueta podría estar influenciada por datos del conjunto de validación [8].

### 2.7.3. Dimensionamiento de la apuesta (Bet sizing)

El dimensionamiento de la apuesta se refiere al proceso de determinar la cantidad de capital que se arriesgará en una operación [8]. Un modelo puede predecir la dirección del precio (clasificación) o la probabilidad de un movimiento (regresión), pero el bet sizing traduce esa predicción en una decisión de inversión concreta. El objetivo es maximizar los rendimientos ajustados por riesgo. Un método común es utilizar una función sigmoidea para convertir las probabilidades de predicción del modelo en un tamaño de apuesta, lo que permite al sistema invertir con más confianza cuando el modelo está más seguro.

### 2.7.4. Ratio de sharpe y sus variantes

El *Sharpe Ratio* [17] es una métrica clave utilizada para evaluar el rendimiento de una inversión ajustado por el riesgo. Este ratio ayuda a determinar la rentabilidad de una inversión en exceso de la tasa libre de riesgo, por unidad de desviación estándar del rendimiento. Cuanto mayor sea el Sharpe Ratio, más atractivo es el rendimiento ajustado por riesgo de la estrategia. La fórmula general se ve en 2.1.

$$S = \frac{R_p - R_f}{\sigma_p} \tag{2.1}$$

Donde:

- $R_p$: es el rendimiento de la cartera.
- $R_f$: es la tasa de rendimiento de un activo libre de riesgo.
- $\sigma_p$: es la desviación estándar de la rentabilidad de la cartera (medida del riesgo).

Es importante destacar que el Ratio de Sharpe tradicional asume que los retornos se distribuyen normalmente (como una campana de Gauss), una premisa que rara vez se cumple en los mercados financieros, en los que los retornos suelen presentar asimetría y colas pesadas. Para una evaluación más realista del riesgo, López de Prado introduce métricas ajustadas que abordan estas limitaciones [8].

Existen variantes de este ratio que abordan ciertas limitaciones, como el Sortino Ratio [18], que solo considera la volatilidad a la baja (riesgo de cola), o el Calmar Ratio [19], que utiliza la máxima caída (max drawdown) como medida de riesgo en lugar de la desviación estándar. Estas variantes son útiles para obtener una perspectiva más completa del perfil de riesgo rendimiento de una estrategia de trading, especialmente en mercados volátiles como el de las criptomonedas.

Para una evaluación aún más rigurosa y para combatir el riesgo de sobreajuste en el backtesting, se pueden considerar las siguientes métricas avanzadas propuestas por López de Prado [8]:

- Probabilidad de sobreajuste de backtest (PBO): mide la probabilidad de que la estrategia seleccionada como "la mejor" dentro de la muestra de entrenamiento rinda por debajo de la mediana en datos fuera de la muestra, simplemente debido al sesgo de selección.
- Probabilistic sharpe ratio (PSR): corrige el Ratio de Sharpe tradicional y lo penaliza si los retornos tienen sesgo negativo (*skewness*), colas pesadas (*kurtosis*) o si el historial de datos es demasiado corto. Proporciona la probabilidad real de que el Sharpe de la estrategia sea mayor que un valor de referencia (*benchmark*).
- Deflated sharpe ratio (DSR): va un paso más allá del PSR y ajusta el umbral de aceptación a partir del número de ensayos independientes (*trials*) y la varianza de esos ensayos. Si se probaron numerosas variaciones de una estrategia, el DSR exigirá un Ratio de Sharpe significativamente más alto para considerar que la estrategia es estadísticamente significativa.

# Capítulo 3

# Diseño e implementación

En este capítulo se desarrollara la solucion alcanzada. Se describen los datos que se procesaron, las estrategias que se probaron, asi como el criterio que se uso para compararlas. Tambien se agregan detalles sobre el diseño de la implementación del bot de trading.

## 3.1. Conjunto de datos y preprocesamiento

Esta sección describe el conjunto de datos utilizado y las estrategias de preprocesamiento aplicadas para el desarrollo del trabajo. Se detallan las consideraciones sobre la frecuencia de los datos, las técnicas de construcción de barras, los métodos de etiquetado y el análisis de la importancia de las características.

### 3.1.1. Conjunto de datos

El trabajo se basó en el análisis de datos del mercado spot de Bitcoin. El mercado spot se define como aquel en el que los activos financieros, en este caso Bitcoin (BTC) frente al Tether (USDT), se compran y venden para su liquidación y entrega inmediata. Las variables disponibles para este mercado incluyen el precio de apertura, el precio de cierre, el valor mínimo y máximo alcanzado, el volumen comercializado en unidades de Bitcoin y en USDT, y la hora exacta en la que se tomó cada medición.

Estos datos se recopilaron desde el 1 de enero de 2020 a través de la plataforma de Binance. Inicialmente, se experimentó con una frecuencia de una hora, la cual presentó la desventaja de acotar el volumen de datos disponibles para el entrenamiento del modelo. Además, se observó que las estrategias probadas con esta frecuencia arrojaban peores resultados. Se infirió que esto se debía, posiblemente, a la menor cantidad de datos disponibles, lo que limitó la capacidad del modelo para aprender patrones robustos. Por lo anterior, se optó por utilizar una frecuencia de un minuto, lo que generó una mejora significativa en el desempeño de las estrategias estudiadas al proporcionar un conjunto de datos más denso y amplio.

### 3.1.2. Estrategias de preprocesamiento

Para el preprocesamiento de los datos, se aplicaron diversas estrategias con el fin de optimizar su calidad y relevancia para el modelo:

- Conversión a micro-Bitcoins (*uBTC*): se realizó una conversión de BTC a *uBTC*, una práctica estándar en el análisis de criptomonedas para manejar unidades más pequeñas y facilitar los cálculos.

- Agrupación por Volumen (*Volume Bars*): se exploraron formas de agrupar los datos no por intervalos de tiempo fijos, sino por volumen en unidades constantes tanto de BTC como de USDT. Adicionalmente, se probaron las *volume imbalance bars* y las *tick imbalance bars*. Las *volume imbalance bars* se construyen cuando se alcanza un volumen neto desequilibrado entre compras y ventas, mientras que las *tick imbalance bars* se forman con un desequilibrio neto en el número de *ticks* (cambios de precio). Tras una investigación exhaustiva de la literatura y pruebas empíricas, se decidió continuar con la agrupación de barras por volumen fijo. Esta elección se fundamentó en que las barras de volumen aportan una mejora notable en las propiedades estadísticas de la distribución del precio de Bitcoin, ya que reducen la autocorrelación y la heterocedasticidad, lo que las hace más adecuadas para el entrenamiento de modelos de *machine learning*. Se adoptó un límite de volumen de 50.000 *uBTC*, el cual proporcionó un equilibrio satisfactorio entre la cantidad de puntos de datos obtenidos y la reducción de la varianza correspondiente a cada barra.

### 3.1.3. Ingeniería de características y análisis de importancia

Para la ingeniería de características, se generó una extensa lista de indicadores técnicos, los cuales se consideran fundamentales en el análisis de mercados financieros. Adicionalmente, se hizo uso de técnicas de reducción de dimensionalidad como el *Análisis de Componentes Principales* (*PCA*). El análisis de características se llevó a cabo utilizando las siguientes métricas:

- Disminución media de impureza (*Mean Decrease Impurity*, MDI): esta métrica cuantifica la importancia de una característica al medir la reducción promedio de la impureza (por ejemplo, Gini impurity o entropía) que cada característica aporta a las divisiones en los árboles de decisión de un modelo de tipo *Random Forest*. Un valor más alto indica una mayor importancia.

- Disminución media de exactitud (*Mean Decrease Accuracy*, MDA): esta técnica evalúa la importancia de una característica cuantificando la caída en el rendimiento del modelo (medido con la puntuación F1 o *F1-score*, derivada de la pérdida logarítmica invertida) cuando los valores de esa característica se permutan aleatoriamente. Una mayor disminución en la exactitud indica una característica más importante.

- Importancia de característica individual (*Single Feature Importance*, SFI): este método evalúa la importancia de cada característica de forma aislada. Para ello, se entrena un modelo únicamente con esa variable y se evalúa su rendimiento. Permite identificar la contribución individual de cada característica sin la influencia de otras.

- Análisis de componentes principales (*Principal Component Analysis*, PCA): se utilizó PCA para la reducción de dimensionalidad, lo que transformó un conjunto de características correlacionadas en un conjunto de características ortogonales denominadas componentes principales. Esto permitió analizar la importancia de estas características ortogonales al comparar sus puntuaciones MDI, MDA, SFI y la Varianza Explicada por PCA, lo que ofrece una perspectiva de la importancia intrínseca y la capacidad de representación de las características originales.

- Correlación tau de Kendall ponderada (*Weighted Kendall's Tau Correlation*): esta métrica se empleó para medir la correlación de rangos entre las diferentes métricas de importancia de características (MDI, MDA, SFI y la Varianza Explicada por PCA). La visualización de esta correlación se realizó a través de mapas de calor (*heatmaps*), lo que facilitó la identificación de consistencias y divergencias en la valoración de la importancia de las características entre los distintos métodos.
- Función de autocorrelación (ACF) y función de autocorrelación parcial (PACF): estas funciones se aplicaron a las características principales (componentes de *PCA*) para analizar su correlación serial. Esto es particularmente relevante en el contexto de series temporales, ya que permite identificar la dependencia de una observación con respecto a observaciones pasadas, lo que influye en la capacidad predictiva del modelo.

Estas técnicas se aplicaron a las características originales, a las características derivadas de *PCA* y a las características temporales (*chronos features*), y los resultados se visualizaron mediante gráficos de barras y mapas de calor de correlación. Con base en este análisis exhaustivo, se determinaron las características más importantes a considerar en el modelo final.

### 3.1.4. Arquitectura del modelo

En esta sección se detalla la arquitectura de Transformers utilizada para la predicción de series de tiempo. Los Transformers, introducidos por [16], son una arquitectura de red neuronal basada en mecanismos de autoatención que han demostrado un rendimiento excepcional en tareas de procesamiento de lenguaje natural y, más recientemente, en series de tiempo.

## 3.2. Estrategias de Referencia (Baselines)

El trabajo de Guilherme Palazzo, titulado "Predicting BTC cryptocurrency price movement in a pre-defined trading volume window using Machine Learning models", se centra en predecir la dirección del movimiento del precio de Bitcoin (BTC) formulando el problema como una tarea de clasificación en lugar de intentar pronosticar el precio exacto.

Principales componentes del trabajo de Palazzo:

- **Muestreo basado en Volumen (Volume Bars)**: Argumentando que los mercados no procesan la información en intervalos de tiempo constantes (lo que genera submuestreo en alta actividad y sobremuestreo en baja actividad), Palazzo rechaza las barras de tiempo tradicionales. En su lugar, agrupa los datos en barras de volumen (específicamente ventanas de 50,000 unidades de BTC).
- **Etiquetado Dinámico**: Inspirándose directamente en las metodologías de Marcos López de Prado (como el enfoque de la triple barrera), no asume un marco de tiempo fijo ni distribuciones predefinidas. Etiqueta los datos evaluando si el retorno futuro supera un umbral dinámico dictado por la desviación estándar local (volatilidad, $\sigma$) multiplicada por una constante predefinida ($\tau$). Para corregir el desbalance natural de las clases resultantes,

utiliza el algoritmo K-Nearest Neighbors (KNN) para hacer undersampling en los datos de entrenamiento.

- **Ingeniería y Selección de Características**: En lugar de operar con precios crudos, utiliza retornos logarítmicos, calcula z-scores y genera múltiples indicadores de análisis técnico (tendencia, volumen y momentum). Tras escalar estas características, emplea el Criterio de Información Mutua (MIC) para seleccionar las 40 variables con mayor poder predictivo. En el caso de la Regresión Logística, aplica previamente el Factor de Inflación de la Varianza (VIF) para eliminar la multicolinealidad.
- **Modelado Riguroso y Resultados**: Entrenó y evaluó tres modelos predictivos: Regresión Logística, Long-Short Term Memory (LSTM) y eXtreme Gradient Boosting (XGBoost). El XGBoost fue el mejor algoritmo, logrando un Área Bajo la Curva (AUC) de 0.66 y un Ratio de Sharpe (anualizado) de 6.27 en el conjunto de prueba, y un Sharpe de 1.08 en la validación estrictamente fuera de muestra, superando con creces a la estrategia benchmark. Para optimizar hiperparámetros sin contaminar los datos (look-ahead bias), usó TimeSeriesSplit de scikit-learn manteniendo la integridad cronológica del conjunto.

Justificación de por qué usar el trabajo de Palazzo como baseline (punto de referencia) para tu investigación:

- **Es la aplicación empírica ideal de la teoría de López de Prado**: Durante tu investigación, has profundizado en las arquitecturas y recomendaciones de López de Prado. El trabajo de Palazzo es un ejemplo perfecto de cómo aterrizar esas ideas teóricas (como el reloj de volumen para evitar distribuciones no IID y los umbrales dinámicos de etiquetado) a un caso de uso real en un mercado de altísima volatilidad como el de las criptomonedas.
- **Aísla el efecto del ruido del mercado**: Al reformular el problema de una regresión de precios exactos a una clasificación direccional usando barras de volumen, Palazzo mitiga la naturaleza no estacionaria y ruidosa del criptomercado. Usar su estructura de datos y pipeline te permitirá comparar si tu nuevo enfoque añade valor genuino, sabiendo que la base de datos subyacente ya está óptimamente estructurada.
- **Rigurosidad metodológica contra el sobreajuste**: Su metodología implementa defensas estrictas contra el sobreajuste y la fuga de información (data leakage). Al utilizar TimeSeriesSplit para la validación cruzada y calcular métricas como z-scores estrictamente con información retrospectiva, establece un marco de prueba que es estadísticamente honesto. Superar este baseline requerirá que tus modelos sean verdaderamente robustos y no el resultado de haber simulado el pasado (backtest overfitting).
- **Métricas claras del .estado del arte"tradicional**: Palazzo ofrece métricas específicas, evaluando desde la precisión pura (AUC = 0.66) hasta el desempeño real del portafolio (Sharpe ratio = 6.27, drawdowns, factor de ganancia) con modelos muy maduros como XGBoost y LSTM. Si estás desarrollando modelos más avanzados (por ejemplo, arquitecturas basadas en Transformers para series de tiempo financieras como PatchTST o Chronos, discutidas en la literatura reciente), el trabajo de Palazzo representa el límite

superior de rendimiento de los algoritmos de la generación anterior, dándote una barrera medible que debes derribar.

### 3.2.1. Técnicas de etiquetado

Se exploraron diversas técnicas de etiquetado para definir los objetivos de predicción del modelo:

- Etiquetado por horizonte fijo: este método asigna etiquetas de acuerdo con el movimiento del precio después de un período de tiempo predefinido, sin considerar la volatilidad del mercado. Se descartó esta técnica al ser invariante a la volatilidad, lo que la hace menos efectiva en mercados financieros dinámicos.
- Etiquetado dinámico: esta técnica también considera un horizonte de tiempo fijo, pero ajusta los umbrales de etiquetado en función de la volatilidad observada en el mercado. Si bien mejora el etiquetado en comparación con el horizonte fijo, aún mantiene una dependencia temporal que puede ser subóptima.
- Etiquetado con barrera triple (*Triple-Barrier Method*): esta fue la técnica más recomendada según la literatura inspeccionada y la que se adoptó. El método de barrera triple varía el muestreo de forma dinámica según la volatilidad del activo. Para ello, se definen tres barreras: una barrera superior para las ganancias, una barrera inferior para las pérdidas y una barrera de tiempo para la salida. La primera barrera que se cruza determina la etiqueta de la observación, lo que permite un etiquetado más adaptativo y robusto.

# Capítulo 4

# Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

## 4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

# Capítulo 5

# Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

## 5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se puedo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

## 5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

# Bibliografía


[1] James Chen. *What Is a Trader, and What Do Traders Do?* https://www.investopedia.com/terms/t/trader.asp. Visitado el 23-09-2023. 2023.

[2] Charles D. Kirkpatrick II y Julie R. Dahlquist. *Technical Analysis: The Complete Resource for Financial Market Technicians*. Financial Times Press, 2006. ISBN: 978-0-13-153113-0.

[3] Qingsong Wen et al. «Transformers in Time Series: A Survey». En: *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence (IJCAI-23)*. 2023, págs. 6778-6786. DOI: 10.24963/ijcai.2023/759. URL: https://doi.org/10.24963/ijcai.2023/759.

[4] Igor Halperin. *Non-Linear and Meta-Stable Dynamics in Financial Markets: Evidence from High Frequency Crypto Currency Market Makers*. 2025. arXiv: 2509.02941 [q-fin.ST]. URL: https://arxiv.org/abs/2509.02941.

[5] Eugene F. Fama. «Efficient Capital Markets: A Review of Theory and Empirical Work». En: *The Journal of Finance* 25.2 (1970), págs. 383-417.

[6] Lucas Coelho e Silva, Gustavo de Freitas Fonseca y Paulo Andre L. Castro. «Transformers and attention-based networks in quantitative trading: a comprehensive survey». En: *Proceedings of the 5th ACM International Conference on AI in Finance*. ICAIF '24. New York, NY, USA: ACM, 2024, págs. 822-830. DOI: 10.1145/3677052.3698684. URL: https://doi.org/10.1145/3677052.3698684.

[7] Joel Paul. «Financial Time Series Analysis with Transformer Models». En: *ResearchGate* (2024). URL: https://www.researchgate.net/publication/387524930_Financial_Time_Series_Analysis_with_Transformer_Models.

[8] Marcos López de Prado. *Advances in Financial Machine Learning*. Hoboken, New Jersey: Wiley, 2018.

[9] Kristina Zucchi. *Derivatives 101*. https://www.investopedia.com/articles/optioninvestor/10/derivatives-101.asp. Visitado el 23-09-2023. 2022.

[10] Ernest P. Chan. *Algorithmic Trading: Winning Strategies and Their Rationale*. John Wiley & Sons, 2013.

[11] Robert Rhea. *The Dow Theory*. New York: Barron's, 1932.

[12] Adam Hayes. *Technical Analysis: What It Is and How to Use It in Investing*. https://www.investopedia.com/terms/t/technicalanalysis.asp. Visitado el 26-09-2023. 2022.

[13] José Francisco López. *Teoría de Dow*. https://economipedia.com/definiciones/teoria-de-dow.html. Visitado el 26-09-2023. 2018.

[14] Stefan Jansen. *Machine Learning for Algorithmic Trading - Second Edition*. Packt, 2020. ISBN: 978-1-83921-771-5.

[15] Gaurav Singhal. *Ensemble Methods in Machine Learning: Bagging Versus Boosting*. https://www.pluralsight.com/guides/ensemble-methods-:-bagging-versus-boosting. Visitado el 31-10-2023. 2020.

[16] Ashish Vaswani et al. «Attention Is All You Need». En: *CoRR* abs/1706.03762 (2017). arXiv: 1706.03762. URL: http://arxiv.org/abs/1706.03762.

[17] William F. Sharpe. «Mutual Fund Performance». En: *The Journal of Business* 39.1 (1966), págs. 119-138.
[18] Frank A. Sortino y Robert van der Meer. «Downside Risk». En: *Journal of Portfolio Management* 17.4 (1991), págs. 27-31.
[19] Terry W. Young. «Calmar Ratio: A Smoother Tool». En: *Futures* 20.11 (1991).