.UBAfiuba
FACULTAD DE INGENIERÍA

Predicción de series de tiempos aplicado al trading de criptomonedas usando la arquitectura de Transformers

Martin Leonardo Centurion

Carrera de Especialización en Inteligencia Artificial

Director: Camilo Argoty

Jurados:

Jurado 1 (pertenencia)
Jurado 2 (pertenencia)
Jurado 3 (pertenencia)

Ciudad de Buenos Aires, Marzo de 2026

Resumen

Este trabajo se enfoca en el estudio y la aplicación de la arquitectura Transformer para la predicción de series de tiempo financieras, específicamente en el contexto de un sistema de trading de criptomonedas. Se desarrolla un modelo Transformer capaz de procesar indicadores técnicos para optimizar decisiones de compra y venta en el par BTC/USDT. La importancia de este enfoque radica en la capacidad del Transformer para capturar dependencias a largo plazo en datos secuenciales, lo que representa una ventaja comparativa en un mercado estocástico y ruidoso. El lector encontrará una revisión del estado del arte, la implementación del modelo, su evaluación frente a una estrategia de 'comprar y esperar', y un análisis de los desafíos de los datos financieros. Se aplican conceptos de aprendizaje profundo, redes neuronales y análisis de series de tiempo para la optimización de estrategias algorítmicas.

Índice general

Resumen I

1. Introducción general 1
1.1. Motivación . . . 1
1.2. Descripción de la problemática . . . 2
1.3. Estado del arte . . . 2
1.4. El desafío de los datos financieros . . . 3
1.5. Objetivos, alcance y requerimientos . . . 4

2. Introducción específica 7
2.1. Trading . . . 7
2.2. Análisis técnico . . . 8
2.3. Aprendizaje supervisado . . . 8
2.4. Optimización de hiperparámetros . . . 9
2.5. Ensambles . . . 9
2.6. Transformers . . . 9
2.7. Metodologías de Evaluación y Gestión de Riesgo . . . 10
2.7.1. Backtesting . . . 10
2.7.2. Validación Cruzada (Cross-Validation) . . . 10
2.7.3. Dimensionamiento de la Apuesta (Bet Sizing) . . . 10
2.7.4. Ratio de Sharpe y sus Variantes . . . 11

3. Diseño e implementación 13
3.1. Análisis del software . . . 13

4. Ensayos y resultados 15
4.1. Pruebas funcionales del hardware . . . 15

5. Conclusiones 17
5.1. Conclusiones generales . . . 17
5.2. Próximos pasos . . . 17

Bibliografía 19

Índice de figuras

1.1. Evolución del precio del par BTC/USDT en el período analizado.[1] 2
1.2. Diagrama conceptual de la arquitectura del sistema de trading. . . 5

Índice de tablas

Capítulo 1

Introducción general

Este capítulo presenta una introducción al problema de la predicción de series de tiempo en el dominio financiero y su aplicación concreta en el desarrollo de un sistema de trading para el mercado de criptomonedas. Se describen el contexto y la motivación que impulsan la elección de la arquitectura Transformer como herramienta principal para el análisis. Además, se detalla la problemática del trading algorítmico, se revisa el estado del arte en la materia, se exponen los desafíos inherentes al manejo de datos financieros y, finalmente, se definen con claridad los objetivos, el alcance y los requerimientos que guiarán este trabajo.

1.1. Motivación

La elección de este trabajo se fundamenta en la confluencia de dos pilares de gran relevancia actual: la complejidad del problema a resolver y la sofisticación de las herramientas seleccionadas para abordarlo. El trading de activos financieros es una actividad que busca generar rentabilidad a partir de las fluctuaciones de los precios en el mercado, lo que representa un desafío intelectual y técnico de alta complejidad debido a la naturaleza inherentemente ruidosa y dinámica de los mercados. Gran parte de las decisiones en este campo se apoyan en el .ªnálisis técnico", que consiste en la interpretación de un amplio abanico de indicadores derivados de la actividad histórica de precios y volúmenes. La combinación manual de estos indicadores para tomar decisiones de compra o venta requiere una experiencia considerable y una intuición desarrollada a lo largo de años. Además, este enfoque manual es difícil de escalar para analizar de manera simultánea la vasta cantidad de información disponible, lo que hace atractiva la idea de desarrollar un modelo de *machine learning* que pueda procesar y ponderar un gran número de indicadores técnicos para optimizar las decisiones de manera sistemática y objetiva.

Por otro lado, la arquitectura Transformer, gracias a su innovador mecanismo de auto-atención, ha demostrado una capacidad excepcional para modelar dependencias a largo plazo en datos secuenciales, consolidándose como el estado del arte en campos como el procesamiento de lenguaje natural. Esta cualidad la convierte en una candidata ideal para el análisis de series de tiempo financieras, donde eventos pasados, incluso lejanos en el tiempo, pueden tener una influencia significativa en el comportamiento futuro de los precios. A diferencia de los modelos recurrentes tradicionales, como las redes LSTM, que pueden tener dificultades para mantener información a través de secuencias muy largas, el Transformer puede teóricamente capturar relaciones entre puntos distantes en el tiempo de manera más efectiva. Esto permitiría, por ejemplo, identificar patrones

complejos que ayuden a evitar operaciones que parecen rentables a corto plazo pero que conllevan un alto riesgo, o, por el contrario, aprovechar oportunidades de baja rentabilidad pero con un riesgo casi nulo.

1.2. Descripción de la problemática

En la comercialización de activos financieros, el objetivo fundamental es generar una ganancia comprando a un precio bajo y vendiendo a un precio más alto. Este principio, aunque simple en apariencia, sería trivial si se pudiera predecir el futuro de los precios con certeza. Sin embargo, la realidad de los mercados es que son sistemas inherentemente estocásticos y no lineales, como se puede apreciar en la volatilidad del precio de Bitcoin en la figura 1.1. Las personas que operan en estos mercados pueden clasificarse a grandes rasgos en dos categorías: los analistas fundamentales, que basan sus decisiones en el valor intrínseco de los activos y factores macroeconómicos, y los analistas técnicos, que se centran en el estudio de patrones históricos de precios y volúmenes para predecir movimientos futuros.

FIGURA 1.1. Evolución del precio del par BTC/USDT en el período analizado.[1]

Este trabajo se enmarca estrictamente en el dominio del análisis técnico, con el propósito de desarrollar un sistema de trading algorítmico diseñado para operar de manera autónoma en el mercado *spot* de criptomonedas. Específicamente, se trabajará con el par BTC/USDT, uno de los más líquidos y volátiles del mercado. El objetivo del sistema es decidir, en intervalos de tiempo discretos, si es más conveniente mantener la posición en Bitcoin (BTC), con la expectativa de que su valor aumente con respecto al Tether (USDT), o si es preferible mantener la posición en USDT, un *stablecoin* anclado al valor del dólar estadounidense, como una forma de protegerse ante una posible caída en el precio del Bitcoin. Esta decisión binaria representa un problema de clasificación que es ideal para ser abordado con técnicas de *deep learning*.

1.3. Estado del arte

El uso de inteligencia artificial para el trading ha ganado un protagonismo creciente en las últimas dos décadas, evolucionando desde modelos estadísticos

[1] Gráfico obtenido de la plataforma de trading Binance.

tradicionales hasta complejas arquitecturas de redes neuronales. Tanto en el ámbito comercial como en el académico, se ha reconocido el potencial de la IA para automatizar y mejorar la toma de decisiones. Empresas como extttAutoTrade.AI o extttFinbrain Technologies ya ofrecen servicios de trading automático basados en señales predictivas generadas por modelos de IA, dirigidos tanto a inversores minoristas como institucionales.

En paralelo, el ámbito académico ha explorado extensamente el uso de *machine learning* para la optimización de portafolios y la predicción de mercados. Los primeros enfoques se basaron en modelos como máquinas de soporte vectorial (SVM) y bosques aleatorios (*random forests*), que demostraron cierta capacidad predictiva. Con la llegada del *deep learning*, las redes neuronales recurrentes (RNN) y, en particular, las redes con memoria a corto y largo plazo (LSTM), se convirtieron en el estándar para el análisis de series de tiempo. Sin embargo, en los últimos años, la arquitectura Transformer ha emergido como una alternativa superior en muchos dominios secuenciales.

A pesar de los avances, muchos de estos enfoques se enfrentan a un obstáculo teórico fundamental: la Hipótesis de los Mercados Eficientes (*EMH*). Esta hipótesis, en su forma débil, sugiere que toda la información pasada ya está reflejada en el precio actual de los activos, lo que haría inútil cualquier intento de obtener ganancias extraordinarias basándose únicamente en el análisis técnico. Aunque la validez de la EMH para el mercado de criptomonedas es un tema de intenso debate, se observa que la eficiencia del mercado tiende a aumentar a medida que este madura, lo que representa un desafío constante para el desarrollo de nuevos modelos predictivos.

1.4. El desafío de los datos financieros

La aplicación de técnicas de *machine learning* a los mercados financieros presenta un conjunto de desafíos únicos que no se encuentran comúnmente en otros dominios:

- Bajo ratio señal-ruido: los movimientos de precios de los activos son inherentemente ruidosos. La "señal"predictiva, que representa la información útil para la predicción, a menudo se encuentra oculta bajo una gran cantidad de fluctuaciones aleatorias o ruido". Esto incrementa significativamente el riesgo de sobreajuste (*overfitting*), donde el modelo aprende a memorizar el ruido de los datos de entrenamiento en lugar de la señal subyacente, resultando en un bajo rendimiento en datos no vistos.
- No estacionariedad: las propiedades estadísticas de las series de tiempo financieras, como la media y la varianza, cambian con el tiempo. Esto se debe a que los mercados están influenciados por factores externos cambiantes, como cambios en la regulación, crisis económicas o avances tecnológicos. Como resultado, los patrones aprendidos en un período de tiempo pueden no ser válidos en el futuro, lo que degrada el rendimiento del modelo a lo largo del tiempo.
- Costos de transacción: en un entorno de trading real, cada operación de compra o venta incurre en costos, como comisiones de la plataforma y deslizamientos (*slippage*). Operar con alta frecuencia, aunque teóricamente podría permitir capturar más oportunidades de mercado, puede llevar a que las

ganancias generadas por el modelo sean completamente consumidas por los costos transaccionales, resultando en una pérdida neta.

Estos factores subrayan la necesidad de un diseño metodológico riguroso y específico para el dominio financiero, que vaya más allá de la simple aplicación de algoritmos estándar y considere estas particularidades.

1.5. Objetivos, alcance y requerimientos

El objetivo principal de este trabajo es estudiar y evaluar rigurosamente el desempeño de la arquitectura Transformer en la predicción de series de tiempo para su aplicación en un sistema de trading de criptomonedas en el mercado *spot* de la plataforma extttBinance.

Para alcanzar este objetivo principal, se han definido los siguientes objetivos específicos:

1. Realizar una revisión exhaustiva del estado del arte sobre la aplicación de modelos de *deep learning*, y en particular la arquitectura Transformer y sus variantes, a la predicción de series de tiempo financieras.
2. Implementar un modelo Transformer que utilice un conjunto de indicadores técnicos como datos de entrada para estimar si es óptimo posicionarse en BTC o en USDT en el par BTC/USDT durante el siguiente intervalo de tiempo.
3. Comparar el desempeño del modelo propuesto con una estrategia de referencia pasiva de çomprar y esperar"(*buy and hold*). El objetivo final no es maximizar la cantidad de USDT acumulado, sino la cantidad de BTC, lo que implica una estrategia de gestión de riesgo a largo plazo.
4. Probar distintas técnicas y configuraciones del modelo, como diferentes variantes de la arquitectura Transformer, distintos conjuntos de características de entrada y optimizaciones de hiperparámetros, para decidir el modelo final con el mejor desempeño.

El alcance de este trabajo se centra en la implementación y evaluación de un sistema de trading algorítmico, cuya arquitectura conceptual se ilustra en la figura 1.2. Este sistema incluye su operación simulada en un entorno de *backtesting* robusto, que utiliza datos históricos fuera de la muestra para evitar el sesgo de anticipación (*lookahead bias*), así como la capacidad de operar en tiempo real a través de la API de extttBinance. Adicionalmente, se buscará determinar una frecuencia de operación que optimice el equilibrio entre la disponibilidad de datos para el entrenamiento del modelo y el impacto de los costos transaccionales en la rentabilidad final.

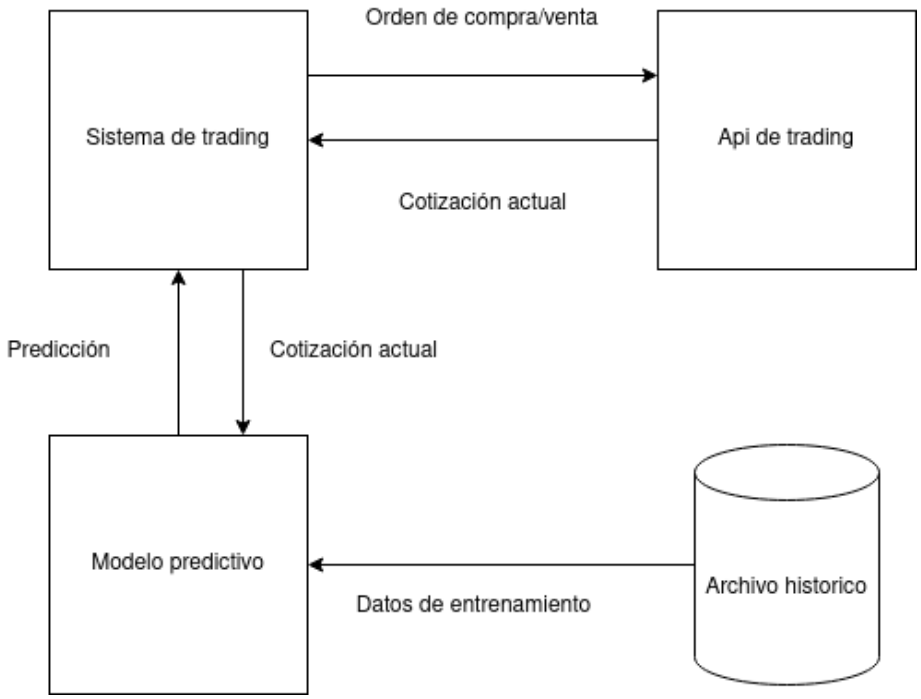

FIGURA 1.2. Diagrama conceptual de la arquitectura del sistema de trading.

Capítulo 2

Introducción específica

En este capítulo se introducen temas con mayor profundidad que en el capítulo previo y se cubren aspectos fundamentales de *trading*, análisis técnico y conceptos clave de aprendizaje automático, indispensables para comprender el desarrollo y los resultados del trabajo.

2.1. Trading

El *trading* es la actividad de comprar y vender activos en mercados financieros con el objetivo de obtener ganancias a corto plazo, diferenciándose de la inversión tradicional por la duración de las posiciones. Mientras que un inversor mantiene posiciones a largo plazo, un *trader* busca aprovechar tendencias de menor duración [[1]].

El objetivo principal de un *trader* es generar ganancias comprando a precios bajos y vendiendo a precios más altos. Los activos comercializados pueden ser acciones, bonos, divisas, *commodities* (como oro o petróleo) y derivados (como futuros u opciones) [[2]].

Los *traders* se pueden clasificar según el tipo de estrategia que emplean:

- *Scalping*: Implica la compra y venta de instrumentos financieros en lapsos muy breves (segundos a minutos) para generar pequeñas ganancias en cada operación.
- *Trading* diario: La duración de las posiciones va desde minutos a horas, con múltiples operaciones abiertas simultáneamente.
- *Swing trading*: Las operaciones pueden durar días o semanas. Se considera menos riesgosa que las anteriores debido a la mayor disponibilidad de tiempo para tomar decisiones.
- *Trading* de eventos: Busca beneficiarse de movimientos rápidos de precio causados por eventos económicos o financieros específicos (adquisiciones de empresas, publicaciones de ganancias, decisiones regulatorias, etc.).

Otra clasificación se basa en el tipo de información utilizada, diferenciando a los analistas fundamentales y a los analistas técnicos, ya introducidos en la sección 1.2.

2.2. Análisis técnico

El análisis técnico es una metodología para pronosticar las direcciones futuras de los precios mediante el estudio de datos históricos del mercado, principalmente el precio y el volumen operado [[3]].

Esta metodología fue formalizada por Charles Dow a fines del siglo XIX y ha sido enriquecida por numerosos investigadores. Actualmente, el análisis técnico incluye cientos de patrones y señales [[4]].

La teoría de Dow establece seis puntos principales [[5]]:

- **El precio lo descuenta todo:** Toda la información disponible sobre un activo ya se encuentra incorporada en su cotización bursátil.
- **Las tres tendencias del mercado:** El mercado se mueve en tendencias alcistas o bajistas. Se distinguen tres tipos de tendencias (ver figura **??**):
  - Tendencias primarias: Son las principales y duran de uno a tres años.
  - Tendencias secundarias o intermedias: Van en dirección contraria a las primarias, pero son de menor tamaño ("correcciones").
  - Tendencias terciarias o menores: Van en dirección contraria a las secundarias y son de menor duración.
- **Las tres fases de las tendencias primarias:** Las tendencias alcistas tienen fases de "acumulación", "participación pública" y "euforia"; las bajistas tienen fases de "distribución", "participación pública" y "pánico".
- **Principio de confirmación:** Para confirmar una tendencia del mercado (alcista o bajista), los índices de industrias y de transportes deben tener la misma tendencia.
- **El volumen bursátil debe confirmar la tendencia:** Si la tendencia es al alza, el volumen debe aumentar con el precio y disminuir cuando baja. Si la tendencia es a la baja, el volumen debe aumentar cuando el precio baja y disminuir cuando sube.
- **La tendencia se mantiene vigente hasta que se demuestre lo contrario:** Una tendencia se considera válida hasta que se confirma una tendencia opuesta.

2.3. Aprendizaje supervisado

El aprendizaje automático (*machine learning*) se clasifica comúnmente en aprendizaje supervisado, no supervisado y por refuerzo. El aprendizaje supervisado se basa en el uso de datos etiquetados para entrenar un modelo que aprenda a predecir una salida a partir de una entrada [[6]].

Esta técnica se divide en dos categorías principales:

- **Clasificación:** El modelo predice una categoría discreta o una etiqueta. Por ejemplo, predecir si un activo subira o bajara en el periodo siguiente.
- **Regresión:** El modelo predice un valor numérico continuo. Por ejemplo, predecir el precio futuro de un activo financiero .

Para este trabajo, se optó por un enfoque de clasificación, donde el modelo predice la dirección del movimiento del precio (subida o bajada) en lugar de la magnitud exacta.

2.4. Optimización de hiperparámetros

Es fundamental distinguir entre los *parámetros* de un modelo y sus *hiperparámetros*. Los parámetros son valores aprendidos por el modelo durante el entrenamiento a partir de los datos (por ejemplo, los pesos en una red neuronal o la pendiente en una regresión lineal). Los hiperparámetros, en cambio, son configuraciones que se definen antes del entrenamiento y no se modifican durante este proceso (por ejemplo, la tasa de aprendizaje o la profundidad de un árbol de decisión) [[6]].

El rendimiento de un modelo depende tanto de sus parámetros como de sus hiperparámetros. La optimización de hiperparámetros es el proceso de buscar la combinación de valores de hiperparámetros que resulta en el mejor desempeño del modelo. Esto a menudo implica entrenar múltiples modelos con diferentes combinaciones y seleccionar el que ofrezca los mejores resultados en un conjunto de validación [[6]]. Aunque la optimización de hiperparámetros es conveniente, puede ser computacionalmente intensiva para modelos complejos, como las redes neuronales profundas o los modelos basados en aprendizaje por refuerzo.

2.5. Ensambles

En el ámbito del aprendizaje automático, los ensambles son el resultado de combinar múltiples modelos entrenados individualmente para obtener un desempeño general superior al que se lograría con un solo modelo [[7]]. La idea es que los puntos débiles de un modelo puedan ser compensados por los puntos fuertes de otros, mejorando la robustez y la precisión de las predicciones. Existen diferentes técnicas de ensamble, como *bagging* y *boosting*, que combinan los modelos de distintas maneras [[7]].

2.6. Transformers

La arquitectura *Transformer*, introducida por Vaswani et al. [[**Vaswani:2017**]], revolucionó el procesamiento de secuencias, especialmente en el ámbito del procesamiento del lenguaje natural (PLN), y ha demostrado ser altamente efectiva también en el análisis de series de tiempo. A diferencia de los modelos recurrentes o convolucionales tradicionales, los *Transformers* se basan completamente en mecanismos de auto-atención (*self-attention*), lo que les permite modelar dependencias de largo alcance en las secuencias de entrada de manera más eficiente y paralelizable.

Los componentes clave de un *Transformer* incluyen:

- **Mecanismo de Auto-atención (Self-Attention):** Permite al modelo ponderar la importancia de diferentes partes de la secuencia de entrada al procesar cada elemento. Cada token (o punto en la serie de tiempo) interactúa con todos los demás tokens, calculando una puntuación de atención que determina cuánto debe enfocarse en cada uno.

- **Codificación Posicional (Positional Encoding):** Dado que el mecanismo de atención no es sensible al orden de los elementos en una secuencia, se añade una codificación posicional a las incrustaciones de entrada para inyectar información sobre la posición relativa de cada elemento.
- **Bloques Encoder-Decoder:** La arquitectura original consiste en un *encoder* y un *decoder*. El *encoder* procesa la secuencia de entrada para crear una representación contextualizada, y el *decoder* utiliza esta representación para generar la secuencia de salida. En aplicaciones de series de tiempo predictivas, a menudo se utiliza solo la parte del *encoder* o variaciones específicas para la tarea.

La capacidad de los *Transformers* para capturar relaciones complejas y no lineales entre puntos distantes en el tiempo los convierte en una herramienta potente para la predicción de series de tiempo financieras, donde los eventos pasados pueden tener un impacto significativo y no trivial en los movimientos futuros del mercado.

2.7. Metodologías de Evaluación y Gestión de Riesgo

2.7.1. Backtesting

El *backtesting* es el pilar fundamental para evaluar una estrategia de *trading*. Consiste en simular el comportamiento de la estrategia utilizando datos históricos para estimar cómo se habría desempeñado en el pasado. Un *backtesting* riguroso debe evitar el sesgo de retrospección (*look-ahead bias*), asegurando que las decisiones del modelo en un punto del tiempo se basen únicamente en información disponible hasta ese momento.

2.7.2. Validación Cruzada (Cross-Validation)

La validación cruzada es una técnica para evaluar la capacidad de generalización de un modelo y prevenir el sobreajuste. Sin embargo, la validación cruzada estándar (como K-Fold) no es adecuada para series de tiempo debido a la dependencia temporal de los datos. En su lugar, se utilizan métodos especializados:

- **Purged K-Fold Cross-Validation:** Esta técnica introduce dos modificaciones clave. Primero, se inserta un .embargo.º período de exclusión después de cada conjunto de validación para evitar que la información futura "se filtre.al conjunto de entrenamiento. Segundo, se "purgan"del conjunto de entrenamiento aquellas observaciones cuya etiqueta podría estar influenciada por datos del conjunto de validación.

2.7.3. Dimensionamiento de la Apuesta (Bet Sizing)

El dimensionamiento de la apuesta se refiere al proceso de determinar la cantidad de capital que se arriesgará en una operación. Un modelo puede predecir la dirección del precio (clasificación) o la probabilidad de un movimiento (regresión), pero el *bet sizing* traduce esa predicción en una decisión de inversión concreta. El objetivo es maximizar los rendimientos ajustados por riesgo. Un método común es utilizar una función sigmoidea para convertir las probabilidades de predicción del modelo en un tamaño de apuesta, permitiendo al sistema invertir con más confianza cuando el modelo está más seguro.

2.7.4. Ratio de Sharpe y sus Variantes

El *Sharpe Ratio* es una métrica clave utilizada para evaluar el rendimiento de una inversión ajustado por el riesgo. Este ratio ayuda a determinar la rentabilidad de una inversión en exceso de la tasa libre de riesgo, por unidad de desviación estándar del rendimiento. Cuanto mayor sea el *Sharpe Ratio*, más atractivo es el rendimiento ajustado por riesgo de la estrategia. La fórmula general es:

$$S = \frac{R_p - R_f}{\sigma_p}$$

Donde:

- R_p: Es el rendimiento de la cartera.
- R_f: Es la tasa de rendimiento de un activo libre de riesgo.
- σ_p: Es la desviación estándar de la rentabilidad de la cartera (medida del riesgo).

Es importante destacar que el Ratio de Sharpe tradicional asume que los retornos se distribuyen normalmente (siguiendo una campana de Gauss), una premisa que rara vez se cumple en los mercados financieros, donde los retornos suelen presentar asimetría y colas pesadas. Para una evaluación más realista del riesgo, López de Prado introduce métricas ajustadas que abordan estas limitaciones.

Existen variantes de este ratio que abordan ciertas limitaciones, como el *Sortino Ratio*, que solo considera la volatilidad a la baja (riesgo de cola), o el *Calmar Ratio*, que utiliza la máxima caída (*max drawdown*) como medida de riesgo en lugar de la desviación estándar. Estas variantes son útiles para obtener una perspectiva más completa del perfil de riesgo-rendimiento de una estrategia de *trading*, especialmente en mercados volátiles como el de las criptomonedas.

Para una evaluación aún más rigurosa y para combatir el riesgo de sobreajuste en el *backtesting*, se pueden considerar las siguientes métricas avanzadas propuestas por López de Prado:

- **Probabilidad de Sobreajuste de Backtest (PBO):** Mide la probabilidad de que la estrategia seleccionada como 'la mejor' dentro de la muestra de entrenamiento termine rindiendo por debajo de la mediana en datos fuera de la muestra, simplemente debido al sesgo de selección.
- **Probabilistic Sharpe Ratio (PSR):** Corrige el Ratio de Sharpe tradicional penalizándolo si los retornos tienen sesgo negativo (*skewness*), colas pesadas (*kurtosis*) o si el historial de datos es demasiado corto. Proporciona la probabilidad real de que el Sharpe de la estrategia sea mayor que un valor de referencia (*benchmark*).
- **Deflated Sharpe Ratio (DSR):** Va un paso más allá del PSR y ajusta el umbral de aceptación basándose en el número de ensayos independientes (*trials*) y la varianza de esos ensayos. Si se probaron numerosas variaciones de una estrategia, el DSR exigirá un Ratio de Sharpe significativamente más alto para considerar que la estrategia es estadísticamente significativa.

Capítulo 3

Diseño e implementación

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

3.1. Análisis del software

La idea de esta sección es resaltar los problemas encontrados, los criterios utilizados y la justificación de las decisiones que se hayan tomado.

Se puede agregar código o pseudocódigo dentro de un entorno lstlisting con el siguiente código:

```
\begin{lstlisting}[caption= "un epígrafe descriptivo"]
las líneas de código irían aquí...
\end{lstlisting}
```

A modo de ejemplo, se muestra el fragmento de código 3.1:

```
#define MAX_SENSOR_NUMBER 3
#define MAX_ALARM_NUMBER  6
#define MAX_ACTUATOR_NUMBER 6

uint32_t sensorValue[MAX_SENSOR_NUMBER];
FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
state_t alarmState[MAX_ALARM_NUMBER];           //ON or OFF
state_t actuatorState[MAX_ACTUATOR_NUMBER];     //ON or OFF

void vControl() {

  initGlobalVariables();

  period = 500 ms;

  while(1) {

    ticks = xTaskGetTickCount();

    updateSensors();

    updateAlarms();

    controlActuators();

    vTaskDelayUntil(&ticks, period);
  }
```

```
28 }
```

CÓDIGO 3.1. Pseudocódigo del lazo principal de control.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se puedo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

[1] James Chen. *What Is a Trader, and What Do Traders Do?* https://www.investopedia.com/terms/t/trader.asp. Visitado el 23-09-2023. 2023.

[2] Kristina Zucchi. *Derivatives 101*. https://www.investopedia.com/articles/optioninvestor/10/derivatives-101.asp. Visitado el 23-09-2023. 2022.

[3] Charles D. Kirkpatrick II y Julie R. Dahlquist. *Technical Analysis: The Complete Resource for Financial Market Technicians*. Financial Times Press, 2006. ISBN: 978-0-13-153113-0.

[4] Adam Hayes. *Technical Analysis: What It Is and How to Use It in Investing*. https://www.investopedia.com/terms/t/technicalanalysis.asp. Visitado el 26-09-2023. 2022.

[5] José Francisco López. *Teoría de Dow*. https://economipedia.com/definiciones/teoria-de-dow.html. Visitado el 26-09-2023. 2018.

[6] Stefan Jansen. *Machine Learning for Algorithmic Trading - Second Edition*. Packt, 2020. ISBN: 978-1-83921-771-5.

[7] Gaurav Singhal. *Ensemble Methods in Machine Learning: Bagging Versus Boosting*. https://www.pluralsight.com/guides/ensemble-methods-:-bagging-versus-boosting. Visitado el 31-10-2023. 2020.