

Ciudad de Buenos Aires, Marzo de 2026

Predicción de series de tiempo aplicado al trading de criptomonedas usando la arquitectura de Transformers

Ing. Martín Leonardo Centurión

Carrera de Especialización en Inteligencia Artificial

Director: Dr. Camilo Argoty

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Resumen

Este trabajo se enfoca en el estudio y la aplicación de la arquitectura Transformer para la predicción de series de tiempo financieras, específicamente en el contexto de un sistema de trading de criptomonedas. Se desarrolla un modelo Transformer capaz de procesar indicadores técnicos para optimizar decisiones de compra y venta en el par BTC/USDT. Se aplican conceptos de aprendizaje profundo, redes neuronales y análisis de series de tiempo para la optimización de estrategias algorítmicas.

Índice general

Resumen	I
1. Introducción general	1
1.1. Motivación	1
1.2. Descripción de la problemática	2
1.3. Estado del arte	3
1.4. El desafío de los datos financieros	3
1.5. Objetivos y alcance	4
2. Introducción específica	7
2.1. Trading y análisis técnico	7
2.2. Aprendizaje supervisado	7
2.3. Optimización de hiperparámetros	8
2.4. Transformers	8
2.5. Metodologías de evaluación y gestión de riesgo	9
2.5.1. Técnicas de selección de características	9
2.5.2. Técnicas de etiquetado	10
2.5.3. Backtesting	10
2.5.4. Validación cruzada	10
2.5.5. Dimensionamiento de la apuesta	11
2.5.6. Ratio de sharpe y sus variantes	11
3. Diseño e implementación	13
3.1. Conjunto de Datos y Preprocesamiento	13
3.1.1. Conjunto de datos	13
3.1.2. Estrategias de preprocesamiento	13
3.1.3. Ingeniería de características y análisis de importancia	14
3.2. Estrategias de referencia	14
3.3. Arquitectura Transformer Propuesta	15
3.4. Estrategia de etiquetado para modelos ml	15
3.5. Framework de Backtesting y Evaluación	16
3.6. Modelos explorados	17
3.7. Diseño del bot	17
4. Ensayos y resultados	19
4.1. Pruebas funcionales del hardware	19
5. Conclusiones	21
5.1. Conclusiones generales	21
5.2. Próximos pasos	21
Bibliografía	23

Índice de figuras

1.1. Evolución del precio del par BTC/USDT en el período analizado. ¹	2
1.2. Diagrama conceptual de la arquitectura del sistema de trading. . .	5
2.1. Representación de alto nivel de Chronos. Fase de tokenización (izquierda), entrenamiento (centro), e infrencia (derecha).	9
3.1. Esta imagen ilustra la aplicación del método de etiquetado de triple barrera sobre un gráfico de precios.	16

Índice de tablas

Capítulo 1

Introducción general

Este capítulo presenta una introducción al problema de la predicción de series de tiempo en el dominio financiero y su aplicación concreta en el desarrollo de un sistema de trading para el mercado de criptomonedas. Se describen el contexto y la motivación que impulsan la elección de la arquitectura Transformer como herramienta principal para el análisis. Además, se detalla la problemática del trading algorítmico, se revisa el estado del arte en la materia, se exponen los desafíos inherentes al manejo de datos financieros y, finalmente, se definen con claridad los objetivos y el alcance de este trabajo.

1.1. Motivación

La elección de este trabajo se fundamenta en la confluencia de dos pilares de gran relevancia actual: la complejidad del problema a resolver y la sofisticación de las herramientas seleccionadas para abordarlo. El trading de activos financieros es una actividad que busca generar rentabilidad a partir de las fluctuaciones de los precios en el mercado [1], lo que representa un desafío intelectual y técnico de alta complejidad debido a la naturaleza inherentemente ruidosa y dinámica de los mercados.

Gran parte de las decisiones en este campo se apoyan en el análisis técnico, que consiste en la interpretación de un amplio abanico de indicadores derivados de la actividad histórica de precios y volúmenes [2]. La combinación manual de estos indicadores para tomar decisiones de compra o venta requiere una experiencia considerable y una intuición desarrollada a lo largo de años. Además, este enfoque manual es difícil de escalar para analizar de manera simultánea la vasta cantidad de información disponible, lo que hace atractiva la idea de desarrollar un modelo de machine learning que pueda procesar y ponderar un gran número de indicadores técnicos para optimizar las decisiones de manera sistemática y objetiva.

Por otro lado, la arquitectura Transformer, gracias a su innovador mecanismo de autoatención, ha demostrado una capacidad excepcional para modelar dependencias a largo plazo en datos secuenciales y se ha consolidado como el estado del arte en campos como el procesamiento de lenguaje natural. Esta cualidad la convierte en una candidata ideal para el análisis de series de tiempo financieras [3], en el que eventos pasados, incluso lejanos en el tiempo, pueden tener una influencia significativa en el comportamiento futuro de los precios. A diferencia de los modelos recurrentes tradicionales, como las redes LSTM, que pueden tener dificultades para mantener información a través de secuencias muy largas, el

Transformer puede teóricamente capturar relaciones entre puntos distantes en el tiempo de manera más efectiva. Esto permitiría, por ejemplo, identificar patrones complejos que ayuden a evitar operaciones que parecen rentables a corto plazo pero que conllevan un alto riesgo, o, por el contrario, aprovechar oportunidades de baja rentabilidad pero con un riesgo casi nulo.

1.2. Descripción de la problemática

En la comercialización de activos financieros, el objetivo fundamental es generar una ganancia mediante la compra a un precio bajo y la venta a un precio más alto. Este principio, aunque simple en apariencia, sería trivial si se pudiera predecir el futuro de los precios con certeza. Sin embargo, la realidad de los mercados es que son sistemas inherentemente estocásticos y no lineales [4], como se puede apreciar en la volatilidad del precio de Bitcoin en la figura 1.1. Las personas que operan en estos mercados pueden clasificarse a grandes rasgos en dos categorías: los analistas fundamentales, que basan sus decisiones en el valor intrínseco de los activos y factores macroeconómicos, y los analistas técnicos, que se centran en el estudio de patrones históricos de precios y volúmenes para predecir movimientos futuros [5].



FIGURA 1.1. Evolución del precio del par BTC/USDT en el período analizado.¹

Este trabajo se enmarca estrictamente en el dominio del análisis técnico, con el propósito de desarrollar un sistema de trading algorítmico diseñado para operar de manera autónoma en el mercado spot de criptomonedas. Específicamente, se trabajó con el par BTC/USDT, uno de los más líquidos y volátiles del mercado. El objetivo del sistema es decidir, en intervalos de tiempo discretos, si es más conveniente mantener la posición en Bitcoin para aprovechar un posible aumento de su valor frente al Tether. Por otro lado, se busca determinar si es preferible conservar la posición en USDT para proteger el capital ante una eventual caída en el precio de la criptomoneda. Esta decisión binaria representa un problema de clasificación que es ideal para ser abordado con técnicas de deep learning.

¹Gráfico obtenido de la plataforma de trading Binance.

1.3. Estado del arte

El uso de inteligencia artificial para el trading ha ganado un protagonismo creciente en las últimas dos décadas y ha evolucionado desde modelos estadísticos tradicionales hasta complejas arquitecturas de redes neuronales [6]. Tanto en el ámbito comercial como en el académico, se ha reconocido el potencial de la IA para automatizar y mejorar la toma de decisiones. Empresas como Finbrain Technologies [7] ya ofrecen servicios de trading automático basados en señales predictivas generadas por modelos de IA, dirigidos tanto a inversores minoristas como institucionales.

En paralelo, el ámbito académico ha explorado extensamente el uso de machine learning para la optimización de portafolios y la predicción de mercados [8]. Los primeros enfoques se basaron en modelos como máquinas de soporte vectorial (SVM) y bosques aleatorios (random forests), que demostraron cierta capacidad predictiva. Con la llegada del deep learning, las redes neuronales recurrentes (RNN) y, en particular, las redes con memoria a corto y largo plazo (LSTM), se convirtieron en el estándar para el análisis de series de tiempo. Sin embargo, en los últimos años, la arquitectura Transformer ha emergido como una alternativa superior en muchos dominios secuenciales.

A pesar de los avances, muchos de estos enfoques se enfrentan a un obstáculo teórico fundamental: la Hipótesis de los Mercados Eficientes (EMH) [5]. Esta hipótesis, en su forma débil, sugiere que toda la información pasada ya está reflejada en el precio actual de los activos, lo que haría inútil cualquier intento de obtener ganancias extraordinarias si se basan únicamente en el análisis técnico. Aunque la validez de la EMH para el mercado de criptomonedas es un tema de intenso debate, se observa que la eficiencia del mercado tiende a aumentar a medida que este madura, lo que representa un desafío constante para el desarrollo de nuevos modelos predictivos.

1.4. El desafío de los datos financieros

La aplicación de técnicas de machine learning a los mercados financieros presenta un conjunto de desafíos únicos que no se encuentran comúnmente en otros dominios:

- Bajo ratio señal ruido: los movimientos de precios de los activos son inherentemente ruidosos. La señal predictiva, que representa la información útil para la predicción, a menudo se encuentra oculta bajo una gran cantidad de fluctuaciones aleatorias o “ruido”. Esto incrementa significativamente el riesgo de sobreajuste (overfitting), y el modelo aprende a memorizar el ruido de los datos de entrenamiento en lugar de la señal subyacente, lo que resulta en un bajo rendimiento en datos no vistos [9].
- No estacionariedad: las propiedades estadísticas de las series de tiempo financieras, como la media y la varianza, cambian con el tiempo. Esto se debe a que los mercados están influenciados por factores externos cambiantes, como cambios en la regulación económica o avances tecnológicos. Como resultado, los patrones aprendidos en un período de tiempo pueden no ser válidos en el futuro, lo que degrada el rendimiento del modelo a lo largo del tiempo [9].

- Costos de transacción: en un entorno de trading real, cada operación de compra o venta incurre en costos, como comisiones de la plataforma y deslizamientos (slippage). operar con alta frecuencia, aunque teóricamente podría permitir capturar más oportunidades de mercado, puede llevar a que las ganancias generadas por el modelo sean completamente consumidas por los costos transaccionales, lo que resulta en una pérdida neta [9].

Estos factores subrayan la necesidad de un diseño metodológico riguroso y específico para el dominio financiero, que vaya más allá de la simple aplicación de algoritmos estándar y considere estas particularidades.

1.5. Objetivos y alcance

El objetivo principal de este trabajo es estudiar y evaluar rigurosamente el desempeño de la arquitectura Transformer en la predicción de series de tiempo para su aplicación en un sistema de trading de criptomonedas en el mercado spot de la plataforma Binance.

Para alcanzar este objetivo principal, se han definido los siguientes objetivos específicos:

1. Realizar una revisión exhaustiva del estado del arte sobre la aplicación de modelos de deep learning (y en particular la arquitectura Transformer y sus variantes) a la predicción de series de tiempo financieras.
2. Implementar un modelo Transformer que utilice un conjunto de indicadores técnicos como datos de entrada para estimar si es óptimo posicionarse en BTC o en USDT en el par BTC/USDT durante el siguiente intervalo de tiempo.
3. Comparar el desempeño del modelo propuesto con una estrategia de referencia pasiva de “comprar y esperar” (buy and hold). El objetivo final no es maximizar la cantidad de USDT acumulado, sino la cantidad de BTC, lo que implica una estrategia de gestión de riesgo a largo plazo.
4. Probar distintas técnicas y configuraciones del modelo, como diferentes variantes de la arquitectura Transformer, distintos conjuntos de características de entrada y optimizaciones de hiperparámetros, para decidir el modelo final con el mejor desempeño.

El alcance de este trabajo se centra en la implementación y evaluación de un sistema de trading algorítmico, cuya arquitectura conceptual se ilustra en la figura 1.2. Este sistema incluye su operación simulada en un entorno de backtesting robusto [9], que utiliza datos históricos fuera de la muestra para evitar el sesgo de anticipación (*lookahead bias*), así como la capacidad de operar en tiempo real a través de la API de Binance. Adicionalmente, se buscará determinar una frecuencia de operación que optimice el equilibrio entre la disponibilidad de datos para el entrenamiento del modelo y el impacto de los costos transaccionales en la rentabilidad final.




FIGURA 1.2. Diagrama conceptual de la arquitectura del sistema de trading.

Capítulo 2

Introducción específica

En este capítulo se cubren aspectos fundamentales de trading, análisis técnico y conceptos clave de aprendizaje automático, indispensables para comprender el desarrollo y los resultados del trabajo.

2.1. Trading y análisis técnico

El trading es la compra y venta de activos financieros a corto plazo para obtener ganancias, diferenciándose de la inversión a largo plazo. Los traders se clasifican por la duración de las operaciones (scalping, diario, swing, eventos) y por el tipo de análisis (fundamental o técnico) que emplean [1, 10, 11].

El análisis técnico pronostica movimientos de precios futuros a través del estudio de datos históricos del mercado, como precio y volumen [2, 12, 13]. Se basa en la Teoría de Dow [14], que postula:

- El precio lo descuenta todo.
- Existen tres tipos de tendencias (primaria, secundaria y terciaria) con fases distintivas.
- Las tendencias deben ser confirmadas por el volumen y la alineación de diferentes índices.
- Las tendencias se mantienen vigentes hasta que haya una señal clara de reversión.

2.2. Aprendizaje supervisado

El aprendizaje automático (machine learning) se clasifica comúnmente en aprendizaje supervisado, no supervisado y por refuerzo. El aprendizaje supervisado se basa en el uso de datos etiquetados para entrenar un modelo que aprenda a predecir una salida a partir de una entrada [15].

Esta técnica se divide en dos categorías principales:

- Clasificación: el modelo predice una categoría discreta o una etiqueta. Por ejemplo, predecir si un activo subirá o bajará en el periodo siguiente.
- Regresión: el modelo predice un valor numérico continuo. Por ejemplo, predecir el precio futuro de un activo financiero .

Para este trabajo, se optó por un enfoque de clasificación, en el que el modelo predice la dirección del movimiento del precio (subida o bajada) en lugar de la magnitud exacta.

En el ámbito del aprendizaje automático, los ensambles son el resultado de combinar múltiples modelos entrenados individualmente para obtener un desempeño general superior al que se lograría con un solo modelo [16]. La idea es que los puntos débiles de un modelo puedan ser compensados por los puntos fuertes de otros, lo que mejora la robustez y la precisión de las predicciones. Existen diferentes técnicas de ensamble, como bagging y boosting, que combinan los modelos de distintas maneras [16].

2.3. Optimización de hiperparámetros

Es fundamental distinguir entre los parámetros de un modelo y sus hiperparámetros. Los parámetros son valores aprendidos por el modelo durante el entrenamiento a partir de los datos (por ejemplo, los pesos en una red neuronal o la pendiente en una regresión lineal). Los hiperparámetros, en cambio, son configuraciones que se definen antes del entrenamiento y no se modifican durante este proceso (por ejemplo, la tasa de aprendizaje o la profundidad de un árbol) [15].

El rendimiento de un modelo depende tanto de sus parámetros como de sus hiperparámetros. La optimización de hiperparámetros es el proceso de buscar la combinación de valores de hiperparámetros que resulta en el mejor desempeño del modelo. Esto a menudo implica entrenar múltiples modelos con diferentes combinaciones y seleccionar el que ofrezca los mejores resultados en un conjunto de validación [15]. Aunque la optimización de hiperparámetros es conveniente, puede ser computacionalmente intensiva para modelos complejos, como las redes neuronales profundas o los modelos basados en aprendizaje por refuerzo.

2.4. Transformers

La arquitectura Transformer, introducida por [17], revolucionó el procesamiento de secuencias y ha demostrado ser altamente efectiva en el análisis de series de tiempo. A diferencia de los modelos recurrentes, los Transformers se basan en mecanismos de autoatención (*self-attention*) para modelar dependencias de largo alcance de manera eficiente.

Recientemente, han surgido modelos fundacionales pre-entrenados que adaptan arquitecturas de lenguaje para el pronóstico de series temporales. Entre ellos destaca Chronos [18], un marco de trabajo que trata las series temporales como un lenguaje. El núcleo de Chronos es su proceso de *tokenización*, que convierte una serie de valores reales en una secuencia de *tokens* discretos mediante dos pasos:

- Escalado (*Scaling*): se normaliza la serie para adecuarla a un rango apropiado para la cuantización.
- Cuantización (*Quantization*): la serie escalada se convierte en *tokens* discretos mediante una cuantización uniforme (*uniform binning*), donde los valores se asignan a uno de B contenedores (*bins*) predefinidos.

Una vez tokenizada la serie, se utiliza una arquitectura Transformer estándar (por ejemplo, T5) que se entrena con un objetivo de lenguaje, como predecir el siguiente *token*, usando una función de pérdida de entropía cruzada. Este enfoque, conocido como regresión por clasificación, permite al modelo aprender patrones temporales complejos sin necesidad de componentes específicos para series de tiempo, como capas de descomposición de tendencia o estacionalidad [18].




FIGURA 2.1. Representación de alto nivel de Chronos. Fase de tokenización (izquierda), entrenamiento (centro), e inferencia (derecha).

Siguiendo la figura 2.1 se ve la fase de tokenización (izquierda), la serie temporal de entrada se somete a un proceso de escalado y cuantización para transformarla en una secuencia de tokens. Durante el entrenamiento (centro), estos tokens se introducen en un modelo de lenguaje, ya sea de arquitectura codificador-decodificador o solo decodificador, el cual se optimiza mediante la pérdida de entropía cruzada. Finalmente, en la etapa de inferencia (derecha), se muestrean tokens de forma autorregresiva para volver a convertirlos en valores numéricos; este proceso se repite para generar múltiples trayectorias que permiten obtener una distribución predictiva completa.

2.5. Metodologías de evaluación y gestión de riesgo

Para garantizar la robustez y viabilidad de una estrategia de trading, es fundamental contar con un marco sólido de evaluación y herramientas para la gestión del riesgo. En esta sección se detallan las metodologías y métricas clave que se utilizarán para validar el desempeño de los modelos y para tomar decisiones informadas sobre la asignación de capital.

2.5.1. Técnicas de selección de características

La selección de características es un paso crucial para reducir la dimensionalidad, mejorar el rendimiento del modelo y evitar el sobreajuste. Se utilizaron diversas métricas para evaluar la importancia de las características generadas:

- **Disminución Media de Impureza (MDI):** específica de modelos basados en árboles como Random Forest, esta métrica mide la importancia de una característica por cuánto reduce la impureza (por ejemplo, impureza de Gini) en los nodos del árbol.

- Disminución Media de Exactitud (MDA): se evalúa la importancia de una característica con una permuta aleatoria de sus valores y se mide la caída resultante en el rendimiento del modelo. Una caída significativa indica que la característica es importante.
- Importancia de Característica Individual (SFI): entrena y evalúa un modelo con una sola característica a la vez para medir su poder predictivo de forma aislada.
- Análisis de Componentes Principales (PCA): aunque es una técnica de reducción de dimensionalidad, se utilizó para transformar características correlacionadas en un conjunto de componentes ortogonales, cuya importancia se evaluó posteriormente con las métricas mencionadas.

2.5.2. Técnicas de etiquetado

El etiquetado define el objetivo que el modelo de aprendizaje supervisado debe predecir. Se exploraron las siguientes técnicas:

- Etiquetado por horizonte fijo: asigna etiquetas (por ejemplo, “sube” o “baja”) según el movimiento del precio después de un intervalo de tiempo fijo. Su principal desventaja es que no se adapta a la volatilidad del mercado.
- Etiquetado dinámico: similar al anterior, pero los umbrales para definir las etiquetas se ajustan en función de la volatilidad reciente del mercado.
- Etiquetado con barrera triple (Triple-Barrier Method): este método, popularizado por López de Prado [9], establece tres barreras para cada observación: una barrera superior (objetivo de ganancia), una inferior (límite de pérdida) y una barrera de tiempo vertical (expiración de la operación). La primera barrera que el precio toca determina la etiqueta. Este enfoque es más robusto porque se adapta dinámicamente a la volatilidad del mercado.

2.5.3. Backtesting

El backtesting es el pilar fundamental para evaluar una estrategia de trading. Consiste en simular el comportamiento de la estrategia al utilizar datos históricos para estimar cómo se habría desempeñado en el pasado. Un backtesting riguroso debe evitar el sesgo de retrospcción (look ahead bias) y asegurar que las decisiones del modelo en un punto del tiempo se basen únicamente en información disponible hasta ese momento [9].

2.5.4. Validación cruzada

La validación cruzada (Cross Validation) es una técnica para evaluar la capacidad de generalización de un modelo y prevenir el sobreajuste. Sin embargo, la validación cruzada estándar (como K-Fold) no es adecuada para series de tiempo debido a la dependencia temporal de los datos. En su lugar, se utilizan métodos especializados:

- Purged K-Fold Cross-Validation: esta técnica introduce dos modificaciones clave. Primero, se inserta un embargo o período de exclusión después de cada conjunto de validación para evitar que la información futura se filtre al

conjunto de entrenamiento. Segundo, purgan del conjunto de entrenamiento aquellas observaciones cuya etiqueta podría estar influenciada por datos del conjunto de validación [9].

2.5.5. Dimensionamiento de la apuesta

El dimensionamiento de la apuesta (Bet sizing) se refiere al proceso de determinar la cantidad de capital que se arriesgará en una operación [9]. Un modelo puede predecir la dirección del precio (clasificación) o la probabilidad de un movimiento (regresión), pero el bet sizing traduce esa predicción en una decisión de inversión concreta. El objetivo es maximizar los rendimientos ajustados por riesgo. Un método común es utilizar una función sigmoidea para convertir las probabilidades de predicción del modelo en un tamaño de apuesta, lo que permite al sistema invertir con más confianza cuando el modelo está más seguro.

2.5.6. Ratio de sharpe y sus variantes

El Ratio de Sharpe [19] es una métrica clave utilizada para evaluar el rendimiento de una inversión ajustado por el riesgo. Este ratio ayuda a determinar la rentabilidad de una inversión en exceso de la tasa libre de riesgo, por unidad de desviación estándar del rendimiento. Cuanto mayor sea el Ratio de Sharpe, más atractivo es el rendimiento ajustado por riesgo de la estrategia. La fórmula general se ve en 2.1.

$$S = \frac{R_p - R_f}{\sigma_p} \quad (2.1)$$

donde:

- R_p : es el rendimiento de la cartera.
- R_f : es la tasa de rendimiento de un activo libre de riesgo.
- σ_p : es la desviación estándar de la rentabilidad de la cartera (medida del riesgo).

Es importante destacar que el Ratio de Sharpe tradicional asume que los retornos se distribuyen normalmente (como una campana de Gauss), una premisa que rara vez se cumple en los mercados financieros, en los que los retornos suelen presentar asimetría y colas pesadas. Para una evaluación más realista del riesgo, López de Prado introduce métricas ajustadas que abordan estas limitaciones [9].

Existen variantes de este ratio que abordan ciertas limitaciones, como el Sortino Ratio [20], que solo considera la volatilidad a la baja (riesgo de cola), o el Calmar Ratio [21], que utiliza la máxima caída (*max drawdown*) como medida de riesgo en lugar de la desviación estándar. Estas variantes son útiles para obtener una perspectiva más completa del perfil de riesgo rendimiento de una estrategia de trading, especialmente en mercados volátiles como el de las criptomonedas.

Para una evaluación aún más rigurosa y para combatir el riesgo de sobreajuste en el backtesting, se pueden considerar las siguientes métricas avanzadas propuestas por López de Prado:

- Probabilidad de sobreajuste de backtest (PBO): mide la probabilidad de que la estrategia seleccionada como “la mejor” dentro de la muestra de entrenamiento rinda por debajo de la mediana en datos fuera de la muestra, simplemente debido al sesgo de selección.
- *Probabilistic Sharpe Ratio* (PSR): corrige el Ratio de Sharpe tradicional y lo penaliza si los retornos tienen sesgo negativo (skewness), colas pesadas (kurtosis) o si el historial de datos es demasiado corto. Proporciona la probabilidad real de que el Sharpe de la estrategia sea mayor que un valor de referencia (benchmark).
- *Deflated Sharpe Ratio* (DSR): va un paso más allá del PSR y ajusta el umbral de aceptación a partir del número de ensayos independientes (trials) y la varianza de esos ensayos. Si se probaron numerosas variaciones de una estrategia, el DSR exigirá un Ratio de Sharpe significativamente más alto para considerar que la estrategia es estadísticamente significativa.

Capítulo 3

Diseño e implementación

En este capítulo se explica el desarrollo de la solución alcanzada. Se describen los datos que se procesaron, las estrategias que se probaron, así como el criterio que se usó para compararlas. También se agregan detalles sobre el diseño de la implementación del bot de trading.

3.1. Conjunto de Datos y Preprocesamiento

Esta sección describe el conjunto de datos utilizado y las estrategias de preprocesamiento aplicadas para el desarrollo del trabajo. Se detallan las consideraciones sobre la frecuencia de los datos, las técnicas de construcción de barras y el análisis de la importancia de las características.

3.1.1. Conjunto de datos

El trabajo se basó en el análisis de datos del mercado spot de Bitcoin. El mercado spot se define como aquel en el que los activos financieros, en este caso Bitcoin (BTC) frente al Tether (USDT), se compran y venden para su liquidación y entrega inmediata. Las variables disponibles para este mercado incluyen el precio de apertura, el precio de cierre, el valor mínimo y máximo alcanzado, el volumen comercializado en unidades de Bitcoin y en USDT, y la hora exacta en la que se tomó cada medición.

Estos datos se recopilaron desde el 1 de enero de 2020 a través de la plataforma de Binance. Inicialmente, se experimentó con una frecuencia de una hora, la cual presentó la desventaja de acotar el volumen de datos disponibles para el entrenamiento del modelo. Además, se observó que las estrategias probadas con esta frecuencia arrojaban peores resultados. Se infirió que esto se debía, posiblemente, a la menor cantidad de datos disponibles, lo que limitó la capacidad del modelo para aprender patrones robustos. Por lo anterior, se optó por utilizar una frecuencia de un minuto, lo que generó una mejora significativa en el desempeño de las estrategias estudiadas al proporcionar un conjunto de datos más denso y amplio.

3.1.2. Estrategias de preprocesamiento

Para el preprocesamiento de los datos, se aplicaron diversas estrategias con el fin de optimizar su calidad y relevancia para el modelo:

- Conversión a micro-Bitcoins (uBTC): se realizó una conversión de BTC a uBTC, una práctica estándar en el análisis de criptomonedas para manejar unidades más pequeñas y facilitar los cálculos.

- Agrupación por Volumen (Volume Bars): se exploraron formas de agrupar los datos no por intervalos de tiempo fijos, sino por volumen en unidades constantes tanto de BTC como de USDT. Adicionalmente, se probaron las volume imbalance bars y las tick imbalance bars. Las volume imbalance bars se construyen cuando se alcanza un volumen neto desequilibrado entre compras y ventas, y las tick imbalance bars se forman con un desequilibrio neto en el número de ticks (cambios de precio). Después de una investigación exhaustiva de la literatura y pruebas empíricas, se decidió continuar con la agrupación de barras por volumen fijo. Esta elección se fundamentó en que las barras de volumen aportan una mejora notable en las propiedades estadísticas de la distribución del precio de Bitcoin, ya que reducen la autocorrelación y la heterocedasticidad, lo que las hace más adecuadas para el entrenamiento de modelos de machine learning. Se adoptó un límite de volumen de 50.000 uBTC, el cual proporcionó un equilibrio satisfactorio entre la cantidad de puntos de datos obtenidos y la reducción de la varianza correspondiente a cada barra.

3.1.3. Ingeniería de características y análisis de importancia

Para la ingeniería de características, se generó una extensa lista de indicadores técnicos. Adicionalmente, se hizo uso de técnicas de reducción de dimensionalidad como el Análisis de Componentes Principales (PCA). Para determinar las características más relevantes para el modelo final, se realizó un análisis de importancia en el cual se utilizó un conjunto de métricas, entre ellas: la Disminución Media de Impureza (MDI), la Disminución Media de Exactitud (MDA) y la Importancia de Característica Individual (SFI). También se analizaron las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de los componentes principales para identificar dependencias temporales.

3.2. Estrategias de referencia

Para establecer un punto de comparación robusto, se tomó como principal referencia el trabajo de Guilherme Palazzo [22]. Su metodología destaca por la aplicación rigurosa de técnicas avanzadas de machine learning financiero, y varios de sus componentes clave fueron adoptados en este trabajo para construir una base sólida sobre la cual evaluar la arquitectura Transformer propuesta.

Los elementos metodológicos que se incorporaron de dicho trabajo son los siguientes:

- Muestreo basado en volumen (Volume bars): se adoptó la técnica de agrupar los datos en barras de volumen constante en lugar de intervalos de tiempo fijos. Este enfoque mitiga problemas comunes en las series de tiempo financieras, como la heterocedasticidad, y mejora la calidad de los datos para el entrenamiento de modelos.
- Formulación como clasificación: al igual que en el trabajo de referencia, el problema se formuló como una tarea de clasificación para predecir la dirección del movimiento del precio (alza o baja), en lugar de intentar predecir el valor exacto del precio.

- Inspiración en el etiquetado dinámico: la estrategia de etiquetado se inspiró en el enfoque de Palazzo de no utilizar horizontes de tiempo fijos. En este trabajo, dicha idea se implementó a través del método de la barrera triple, que se adapta dinámicamente a la volatilidad del mercado.
- Validación de modelos basados en árboles: el éxito de XGBoost en el trabajo de referencia sirvió como validación para su uso como un componente eficaz en nuestra arquitectura final, en conjunto con los *embeddings* generados por Chronos.

Al integrar estos componentes, se asegura que la evaluación del rendimiento del modelo Transformer se realice contra una estrategia de referencia competitiva y bien fundamentada en el estado del arte.

3.3. Arquitectura Transformer Propuesta

Para la arquitectura principal de este trabajo, se utilizó el modelo fundacional Chronos, cuya conceptualización fue detallada en el Capítulo 2. En lugar de utilizar el modelo para pronóstico directo, se aprovechó su capacidad para generar representaciones ricas de las series de tiempo.

El enfoque implementado fue el siguiente:

1. Se tomaron las series de tiempo de los indicadores técnicos seleccionados.
2. Cada serie se procesó con un modelo Chronos pre-entrenado para extraer los *embeddings* de sus capas ocultas. Estos *embeddings* son vectores de alta dimensionalidad que encapsulan la información contextual y los patrones temporales aprendidos por el Transformer.
3. Los *embeddings* resultantes de todos los indicadores se concatenaron para formar un único vector de características.
4. Este vector de características se utilizó como entrada para un modelo tabular más tradicional y computacionalmente eficiente, en este caso, XGBoost o LightGBM, que fue el encargado de realizar la tarea de clasificación final (predecir si el precio subirá o bajará).

Esta estrategia de dos pasos permite combinar el poder de los modelos fundacionales para la extracción de características complejas con la eficiencia y robustez de los modelos basados en árboles para la clasificación en datos tabulares. Finalmente, se experimentó con diferentes tamaños del modelo Chronos (small, base y large) para analizar el compromiso entre el rendimiento predictivo y el costo computacional.

3.4. Estrategia de etiquetado para modelos ml

Para definir el objetivo de predicción del modelo, se evaluaron varias técnicas de etiquetado. Tras analizar los métodos de horizonte fijo y etiquetado dinámico, se adoptó el método de la barrera triple (Triple-Barrier Method). Esta técnica, recomendada en la literatura para mercados financieros, ofrece un enfoque más adaptativo y robusto al definir las etiquetas en función de la volatilidad del activo, con barreras para ganancias, pérdidas y tiempo de expiración. Para etiquetar un punto se puede elegir una etiqueta independiente para la barrera vertical o

agruparla con las barreras horizontales según si el punto final es mayor o menor que el inicial, si es menor se agrupa con la etiqueta correspondiente a la barrera inferior y, si es mayor, con la superior. Esta alternativa permite mantener las clases a predecir balanceadas con lo cual fue la elegida.



FIGURA 3.1. Esta imagen ilustra la aplicación del método de etiquetado de triple barrera sobre un gráfico de precios.

En la figura 3.1 se ve como a partir de un punto de Incepción (inicio de la operación), se definen tres límites: una barrera de ganancia superior (púrpura) y una barrera de pérdida inferior (cian) que determinan si la operación se clasifica como positiva o negativa si el precio las toca, y una barrera de tiempo vertical (negra) que sirve de vencimiento, etiqueta la posición por su rendimiento hasta ese momento si ninguna barrera horizontal fue alcanzada previamente

3.5. Framework de Backtesting y Evaluación

Para asegurar una evaluación rigurosa y libre de sesgos, se implementó un motor de backtesting a medida en Python. Esta decisión se tomó debido a la necesidad de utilizar metodologías avanzadas como la validación cruzada combinatoria con purga y embargo (Combinatorially Purged Cross-Validation). Este método es esencial para prevenir la fuga de información y el sobreajuste al evaluar modelos en series de tiempo financieras, lo que garantiza que el rendimiento medido sea una estimación realista del comportamiento del modelo en datos futuros.

La evaluación de los modelos se centró exclusivamente en su rendimiento en el backtest, lo que separa estrictamente esta fase de la optimización de hiperparámetros. Dicha búsqueda se realizó una única vez durante la etapa de investigación y validación del modelo, con un conjunto de datos distinto al de la evaluación final.

Al tratarse de un problema de clasificación, y por el desbalance de clases inherente a las señales de trading, se utilizó la métrica F1 ponderada por clase para evaluar el desempeño. Esta métrica proporciona una medida balanceada entre la precisión y la exhaustividad del modelo, ajustada a la frecuencia de cada clase, lo que la hace más representativa que la exactitud simple.

3.6. Modelos explorados

Durante la fase de investigación, se exploró un amplio espectro de modelos para establecer un punto de referencia y comprender la complejidad del problema.

Inicialmente, se evaluaron estrategias de trading clásicas basadas en indicadores técnicos, como el cruce de medias móviles, las bandas de Bollinger, el MACD y las divergencias en el RSI. Si bien estos métodos son populares, demostraron ser demasiado rígidos, poco adaptativos, y propensos al sobreajuste.

Posteriormente, se probaron modelos estadísticos tradicionales para series temporales, incluyendo ARIMA, SARIMA, y variantes más complejas como ARIMAX con GARCH como variable exógena y Prophet de Facebook. Estos modelos, aunque más sofisticados, lucharon por capturar las dinámicas no lineales y no estacionarias del precio de Bitcoin y no superaron a un desempeño aleatorio.

Luego, se exploraron modelos que sean “drop in replacements” al marco presentado por [22]. Para seguir con la recomendación de López de Prado sobre la idoneidad de los modelos basados en árboles tipo “random forest” para datos financieros. Además, se exploraron alternativas a XGBoost. Se utilizó la biblioteca AutoGluon, que permite entrenar y comparar de forma automática un conjunto de modelos tabulares de última generación, incluyendo diferentes configuraciones de redes neuronales y ensambles, para encontrar un posible reemplazo al modelo de Palazzo.

Finalmente, en cuanto a la arquitectura principal de Chronos, se experimentó con diferentes tamaños del modelo T5 (small, base y large) para analizar el compromiso entre el rendimiento predictivo y el costo computacional, se busca el equilibrio óptimo para una implementación práctica.

3.7. Diseño del bot

El bot de trading se diseñó con una arquitectura modular para facilitar su configuración, mantenimiento y extensibilidad. Se divide en cuatro componentes principales que operan de forma desacoplada:

1. Orquestador: es el punto de entrada de la aplicación. Su función es instanciar, configurar y conectar los demás componentes. Inicia el ciclo de operación del bot.
2. Motor del Bot: contiene el bucle principal de ejecución. En cada iteración, orquesta el flujo de trabajo: solicita los datos más recientes del mercado al

módulo de intercambio, pasa estos datos al módulo de estrategia para obtener una señal de trading y, si la señal lo indica, instruye al módulo de intercambio para que ejecute la orden correspondiente.

3. Módulo de Exchange: abstrae toda la comunicación con la API del exchange de criptomonedas. Es responsable de obtener datos de mercado (precios, volúmenes) y de ejecutar órdenes (compra, venta). Su diseño intercambiable permite adaptar el bot a diferentes plataformas (por ejemplo, Binance, KuCoin) con mínimas modificaciones.
4. Módulo de Estrategia: carga el modelo de machine learning pre-entrenado (en este caso, el ensamble de Chronos y XGBoost) y lo utiliza para procesar los datos de mercado y generar una señal de trading: comprar, vender o mantener.

En esencia, el bot opera en un ciclo continuo: recolecta datos, predice una señal con el modelo y actúa sobre esa predicción. Esta separación de responsabilidades garantiza que la lógica de la estrategia de trading esté completamente aislada de los detalles de implementación de la comunicación con el mercado. de la comunicación con el mercado.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] James Chen. *What Is a Trader, and What Do Traders Do?* <https://www.investopedia.com/terms/t/trader.asp>. Visitado el 23-09-2023. 2023.
- [2] Charles D. Kirkpatrick II y Julie R. Dahlquist. *Technical Analysis: The Complete Resource for Financial Market Technicians*. Financial Times Press, 2006. ISBN: 978-0-13-153113-0.
- [3] Qingsong Wen et al. «Transformers in Time Series: A Survey». En: *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence (IJCAI-23)*. 2023, págs. 6778-6786. DOI: [10.24963/ijcai.2023/759](https://doi.org/10.24963/ijcai.2023/759). URL: <https://doi.org/10.24963/ijcai.2023/759>.
- [4] Igor Halperin. *Non-Linear and Meta-Stable Dynamics in Financial Markets: Evidence from High Frequency Crypto Currency Market Makers*. 2025. arXiv: [2509.02941](https://arxiv.org/abs/2509.02941) [q-fin.ST]. URL: <https://arxiv.org/abs/2509.02941>.
- [5] Eugene F. Fama. «Efficient Capital Markets: A Review of Theory and Empirical Work». En: *The Journal of Finance* 25.2 (1970), págs. 383-417.
- [6] Lucas Coelho e Silva, Gustavo de Freitas Fonseca y Paulo Andre L. Castro. «Transformers and attention-based networks in quantitative trading: a comprehensive survey». En: *Proceedings of the 5th ACM International Conference on AI in Finance*. ICAIF '24. New York, NY, USA: ACM, 2024, págs. 822-830. DOI: [10.1145/3677052.3698684](https://doi.org/10.1145/3677052.3698684). URL: <https://doi.org/10.1145/3677052.3698684>.
- [7] *Finbrain Technologies*. <https://finbrain.tech>. Visitado el 11-04-2026.
- [8] Joel Paul. «Financial Time Series Analysis with Transformer Models». En: *ResearchGate* (2024). URL: https://www.researchgate.net/publication/387524930_Financial_Time_Series_Analysis_with_Transformer_Models.
- [9] Marcos López de Prado. *Advances in Financial Machine Learning*. Hoboken, New Jersey: Wiley, 2018.
- [10] Kristina Zucchi. *Derivatives 101*. <https://www.investopedia.com/articles/optioninvestor/10/derivatives-101.asp>. Visitado el 23-09-2023. 2022.
- [11] Ernest P. Chan. *Algorithmic Trading: Winning Strategies and Their Rationale*. John Wiley & Sons, 2013.
- [12] Robert Rhea. *The Dow Theory*. New York: Barron's, 1932.
- [13] Adam Hayes. *Technical Analysis: What It Is and How to Use It in Investing*. <https://www.investopedia.com/terms/t/technicalanalysis.asp>. Visitado el 26-09-2023. 2022.
- [14] José Francisco López. *Teoría de Dow*. <https://economipedia.com/definiciones/teoria-de-dow.html>. Visitado el 26-09-2023. 2018.
- [15] Stefan Jansen. *Machine Learning for Algorithmic Trading - Second Edition*. Packt, 2020. ISBN: 978-1-83921-771-5.
- [16] Gaurav Singhal. *Ensemble Methods in Machine Learning: Bagging Versus Boosting*. <https://www.pluralsight.com/guides/ensemble-methods--bagging-versus-boosting>. Visitado el 31-10-2023. 2020.
- [17] Ashish Vaswani et al. «Attention Is All You Need». En: CoRR abs/1706.03762 (2017). arXiv: [1706.03762](http://arxiv.org/abs/1706.03762). URL: <http://arxiv.org/abs/1706.03762>.

- [18] Abdul Fatir Ansari et al. *Chronos: Learning the Language of Time Series*. 2024. arXiv: [2403.07815](https://arxiv.org/abs/2403.07815) [cs.LG].
- [19] William F. Sharpe. «Mutual Fund Performance». En: *The Journal of Business* 39.1 (1966), págs. 119-138.
- [20] Frank A. Sortino y Robert van der Meer. «Downside Risk». En: *Journal of Portfolio Management* 17.4 (1991), págs. 27-31.
- [21] Terry W. Young. «Calmar Ratio: A Smoother Tool». En: *Futures* 20.11 (1991).
- [22] Guilherme Palazzo. «Predicting BTC cryptocurrency price movement in a pre-defined trading volume window using Machine Learning models». Advisor: Prof. PhD. Elton Felipe Sbruzzi. Co-advisor: Prof. PhD. Michel Carlo Rodrigues Leles. Dissertation of Master of Science. São Jos'e dos Campos: Instituto Tecnol'ogico de Aeron'utica y Universidade Federal de São Paulo, 2023, 73f.