

Predicción de series de tiempo para trading de criptomonedas con Transformers

Carrera de Especialización en Inteligencia Artificial — FIUBA

Ing. Martín Leonardo Centurión

Junio de 2026

Director: Dr. Camilo Argoty


Contexto del trabajo

Aplicación de la arquitectura

Transformer a la predicción de series de tiempo financieras para trading de criptomonedas.

Un modelo que procesa **indicadores técnicos** y decide en cada barra: **BTC** o **USDT**.

Combina **deep learning**, redes neuronales y análisis de series de tiempo.



Motivación y problema


Motivación

- Criptomonedas: volátiles, ruidosas, no lineales
- Cientos de indicadores técnicos disponibles
- ML: **pondera indicadores** de forma sistemática
- Transformer: **autoatención** para dependencias largas
- Supera a LSTM en secuencias extensas



El problema

- Mercados: **estocásticos y no lineales**
- Análisis técnico: patrones en precios y volúmenes
- Par **BTC/USDT** en Binance, mercado spot
- Decisión binaria: ¿**BTC** o **USDT**?
→ clasificación
- Objetivo: maximizar **BTC acumulado** (largo plazo)



Estado del arte

Era	Enfoque
Clásico	SVM, RF
Deep learning	RNN, LSTM
Hoy	Transformer ✓

Chronos


TimesFM

Moirai

EMH: en cripto,
debate empíricamente abierto



EVOLUCIÓN DE MODELOS EN TRADING: HACIA LA ATENCIÓN GLOBAL



De métodos estadísticos y redes recurrentes a arquitecturas complejas de atención global para capturar patrones a largo plazo.

Bajo SNR

Señal oculta
bajo ruido aleatorio
→ riesgo de
overfitting

No estacionariedad

La distribución
cambia con el tiempo
→ patrones no
generalizan

Costos de transacción

0,1 % por trade
consume ganancias
→ incluido en
el backtest

Objetivos

-  Revisar el estado del arte: deep learning en finanzas
-  Implementar un clasificador BTC/USDT con Transformer
-  Comparar **4 familias** de modelos con el mismo framework
-  Validar el modelo final con **CSCV** y **CPCV**
-  Desplegar un bot de trading operativo vía API Binance

Marco teórico

Trading y análisis técnico

Tipos de traders

Por duración:

- **Scalping:** segundos o minutos
- **Diario:** intraday, sin overnight
- **Swing:** días a semanas
- **Eventos:** reacción a noticias

Por análisis:

Fundamental

Técnico

Algorítmico

Este trabajo: análisis técnico algorítmico

Indicadores usados

- **Momentum:** RSI, ROC, Williams %R
- **Tendencia:** MACD, ADX, Aroon
- **Volatilidad:** Bollinger Bands, Keltner

Aprendizaje supervisado


☰ Tarea: **clasificación binaria** (no regresión)

📊 Métrica: **F1 ponderado** (clases desbalanceadas)

⚙️ **Optuna**: búsqueda bayesiana eficiente


🗄️ Solo sobre datos de entrenamiento

✅ Holdout final: **una única evaluación**




Chronos — Transformer para series de tiempo


Tokenización de Series Temporales



Entrenamiento



Inferencia



T5

Bolt

Chronos-2

Ansari et al. (2024) — *Chronos: Learning the Language of Time Series*


Etiquetado y validación sin data leakage

» Triple-barrier labeling

- Barrera superior: objetivo de ganancia
- Barrera inferior: límite de pérdida
- Barrera temporal: expiración
- Adaptativa a la volatilidad dinámica

⌵ Purged K-Fold CV

- K-Fold estándar: **no válido** en series de tiempo
- Purgado + embargo (1–5 %)



Rendimiento ajustado por riesgo

- **Sharpe**: retorno / desviación estándar
- **Sortino**: solo volatilidad a la baja
- **Calmar**: retorno / max drawdown
- **PSR**: corrige asimetría y kurtosis
- **DSR**: penaliza búsqueda exhaustiva

Anti-overfitting

PBO: ¿ganó por azar?


CSCV: estima PBO en C combinaciones

CPCV: M caminos disjuntos
→ distribución del rendimiento
OOS

Datos y preprocesamiento

Pipeline de datos

1. **Klines 1 min** — Binance, 2020–2025
2. **Barras de volumen** (50 000 uBTC) — ↓ autocorrelación
3. **Diferenciación fraccional** ($d \approx 0,4$) — ADF 95 %
4. **Indicadores técnicos**: RSI, Bollinger, MACD...
5. **StandardScaler** — ajustado solo en train
6. **Triple-barrier labeling** ($\tau > 0,98$)



Experimentos y resultados

Algoritmos de trading clásicos

Clasificador	F1	Std
BollingerBands	0,511	0,022
RSIDivergence	0,508	0,001
MaCrossover	0,501	0,002
MACD	0,499	0,002
SmaCross	0,498	0,002

- ✗ Ninguno supera $F1 = 0,51$
- ✓ RSIDivergence: std = 0,001 — más confiable
- ⚠ BollingerBands: mayor techo, mayor riesgo
- 🔍 6 clasificadores · 184 trials

El análisis técnico simple no captura señal

Modelos estadísticos — ARIMA, GARCH, Kalman

Modelo	F1 máx	Std
ARIMA	0,500	0,118
ARIMA-GARCH	0,495	0,116
SARIMA	0,486	0,046
Kalman-ARIMA	0,418	0,165

✗ Ninguno supera el azar

↓ Más complejidad = peor resultado

⚠ Std 0,118 → fallas catastróficas (F1 → 0)

🔑 threshold $\approx 10^{-6}$, corr = -0,93

PBO = 0: consistentemente al nivel del azar

Machine Learning — XGBoost y AutoGluon

Algoritmo	F1 máx	n
XGBoost Palazzo	0,647	60
AutoGluon Palazzo	0,639	20

max_depth=4 · lr=0,003 ·

n_est=373

Mejor AutoGluon: LightGBMXT_BAG_L1

↑ F1: 0,50 → 0,65 — primer salto real

⌚ AutoGluon: misma calidad, 10× más lento

⊖ PCA no aporta en ningún trial

✓ $\tau > 0,98$: etiquetas menos frecuentes, más limpias

PBO = 0,486 — selección moderada


Transformer — 3 familias Chronos

Familia	Pipeline	F1 máx	Std
Embeddings	ChronosFeature T5-small	0,633	0,022
Embeddings	ChronosBoltFeature	0,628	0,008
Meta-etiquetado	ChronosMetaLabeling	0,657	—
Fine-tuning	FinetuneToClass (Chronos-2)	0,819	—

Meta-filtro: degrada el F1 en 6 de 8 runs

Fine-tuning end-to-end: **+0,16 F1** sobre embeddings

Resumen — 4 familias de modelos



0,819

F1 OOS — Transformer

+0,16

Brecha vs. 2° mejor

Mismo framework · mismos datos
· misma métrica

Selección del modelo — CSCV cruzado

Experimento	IS	OOS
FinetuneToClass	98,6 %	98,6 %
Finetuned_Feature	1,4 %	1,4 %
Resto (5 exp.)	0 %	0 %

$N=203$ trials, $C=70$ combinaciones, PBO
= 0

0,819

F1 OOS — modelo final

`chronos-2-small`

$\tau = 0,910$

`volume_threshold = 45 988`

Validación final — CPCV (5 caminos disjuntos)

Camino	F1
1	0,8219
2	0,8235
3	0,8221
4	0,8303
5	0,8277
Media	$0,825 \pm 0,003$

- ✓ Std = 0,003 — rendimiento estable
- ✓ Caminos 4 y 5 (más recientes) no caen
- ✓ F1 CPCV (0,825) > F1 Optuna (0,818)
- ✓ 17 330 predicciones OOS totales


$0,825 \pm 0,003$
F1 medio CPCV — sin sobreajuste

Conclusiones

Conclusiones y próximos pasos

✓ Logros

- Pipeline completo: 3M+ filas BTC/USDT
- ARIMA y trading clásico: nivel del azar
- XGBoost: primer salto real ($F1 = 0,65$)
- Chronos fine-tuning: $F1 = 0,819$, validado
- Bot operativo con stop-loss automático



➔ Próximos pasos

Bet sizing · Ensemble · HRP ·
Microestructura

¡Gracias!

Ing. Martín Leonardo Centurión

centurionm.leo@gmail.com

¿Preguntas?

Respaldo — Hiperparámetros XGBoost Palazzo

Parámetro	Valor
max_depth	4
learning_rate	0,00328
n_estimators	373
tau	1,261
volume_threshold	28 522
use_pca	False

Respaldo — Hiperparámetros modelo final Chronos

Parámetro	Valor
Modelo base	autogluon/chronos-2-small
τ	0,910
volume_threshold	45 988
prediction_length	2
pct_embargo	0,05
n_splits	3

Respaldo — Sensibilidad modelos estadísticos

Modelo	Parámetro	Corr	Interpretación
ARIMA-family	threshold	−0,93	Umbral cercano a cero es crítico
ARIMAXGARCH	threshold	−0,99	Umbrales altos degradan el modelo
ARIMAClassifier	lookback	−0,37	Historial corto (720 h) preferido
ARIMAXGARCH	q (MA)	+0,85	Orden MA alto es mejor

Respaldo — Barras de volumen vs. barras temporales

Barras de tiempo (1 min)

- Muestreo uniforme en el tiempo
- Alta autocorrelación en baja actividad

Barras de volumen (50 000 μ BTC)

- Muestreo por actividad real
- Menor autocorrelación y heterocedasticidad
- Mayor resolución en alta volatilidad



Respaldo — Diferenciación fraccional

- $d = 1$: serie de retornos — elimina demasiada memoria
- $d = 0$: precio original — no estacionario
- $d \approx 0,4$: mínimo que garantiza estacionariedad (ADF 95 %)

Preserva la mayor cantidad de contexto histórico posible sin violar estacionariedad

$$d = 0,4$$

Punto óptimo entre
memoria e información