

Predicción de series de tiempo aplicado al trading de criptomonedas usando la arquitectura de Transformers

Carrera de Especialización en Inteligencia Artificial



Alumno

Ing. Martín Leonardo Centurión

Director

Dr. Camilo Argoty

Junio de 2026

Jurados

Esp. Ing. Pablo M. Gomez Verdini

Esp. Lic. Bárbara Cocco

Esp. Ing. Maria Fabiana Cid

Contexto del trabajo

Aplicación de la arquitectura

Transformer a la **predicción de series de tiempo financieras** para trading de criptomonedas.

Un modelo que procesa **indicadores técnicos** y decide en cada barra: **BTC** o **USDT**.


Combina **deep learning**, **redes neuronales** y **análisis de series de tiempo**.



1. Motivación y problema

Motivación

- Criptomonedas: volátiles, ruidosas, no lineales.
- Cientos de indicadores técnicos disponibles.
- ML: **pondera indicadores** de forma sistemática.
- Transformer: **autoatención** para dependencias largas.




El problema

- Mercados: **estocásticos y no lineales**.
- Análisis técnico: patrones en precios y volúmenes.
- Par **BTC/USDT** en Binance, mercado spot.
- Decisión binaria: ¿**BTC** o **USDT**? → clasificación.
- Objetivo: maximizar **BTC acumulado** (largo plazo).



EVOLUCIÓN DE MODELOS EN TRADING: HACIA LA ATENCIÓN GLOBAL



De métodos estadísticos y redes recurrentes a arquitecturas complejas de atención global para capturar patrones a largo plazo.

Desafíos del dominio

Bajo SNR

Señal oculta
bajo ruido aleatorio
→ riesgo de
overfitting.

No estacionariedad

La distribución
cambia con
el tiempo
→ patrones no
generalizan.

Costos de transacción

0,1% por trade
consume ganancias
→ incluido en
el backtest.

Objetivos

-  Revisar el estado del arte: deep learning en finanzas.
-  Implementar un clasificador BTC/USDT con Transformer.
-  Comparar **4 familias** de modelos con el mismo framework.
-  Validar el modelo final con **CSCV** y **CPCV**.
-  Desplegar un bot de trading operativo vía API Binance.

2. Marco teórico

Trading y análisis técnico

Tipos de traders

Por duración:

- **Scalping:** segundos o minutos.
- **Diario:** intraday, sin overnight.
- **Swing:** días a semanas.
- **Eventos:** reacción a noticias.

Por análisis:

Fundamental

Técnico

Algorítmico

Este trabajo: análisis **técnico algorítmico**.

Indicadores usados

- **Momentum:** RSI, ROC, Williams %R.
- **Tendencia:** MACD, ADX, Aroon.
- **Volatilidad:** Bollinger Bands, Keltner.

Indicadores técnicos

Categoría	Indicadores
Momentum	RSI, AO, Williams %R, ROC
Tendencia	MACD, ADX, Aroon, CCI, Vortex
Volatilidad	Bollinger, Keltner, Donchian
Retornos	pct_change , retardos
Embeddings	Chronos → features tabulares

Selección: MDI · MDA · SFI · ACF/PACF

+25

features por barra

use_pca=False: correlaciones
entre indicadores contienen
señal.

Aprendizaje supervisado


☰ Tarea: **clasificación binaria** (no regresión).

📊 Métrica: **F1 ponderado** (clases desbalanceadas).

⚙️ **Optuna**: búsqueda bayesiana eficiente.


🗄️ Solo sobre datos de entrenamiento.

✅ Holdout final: **una única evaluación**.




Chronos: Transformer para series de tiempo


Tokenización de Series Temporales



Entrenamiento



Inferencia



T5

Bolt


Chronos-2

Ansari et al. (2024) — *Chronos: Learning the Language of Time Series*

Etiquetado y validación sin data leakage

Triple-barrier labeling

- Barrera superior: objetivo de ganancia.
- Barrera inferior: límite de pérdida.
- Barrera temporal: expiración.
- Adaptativa a la volatilidad dinámica.



Rendimiento ajustado por riesgo

- **Sharpe**: retorno / desviación estándar.
- **Sortino**: solo volatilidad a la baja.
- **Calmar**: retorno / max drawdown.
- **PSR**: corrige asimetría y kurtosis.
- **DSR**: penaliza búsqueda exhaustiva.

Anti-overfitting

PBO: ¿ganó por azar?

CSCV: estima PBO en C combinaciones.


CPCV: M caminos disjuntos.

→ distribución del rendimiento OOS.

3. Datos y preprocesamiento

Pipeline de datos

1. **Klines 1 min** — Binance, 2020–2025.
2. **Barras de volumen** (50 000 uBTC) — ↓ autocorrelación.
3. **Diferenciación fraccional** ($d \approx 0,4$) — ADF 95 %.
4. **Indicadores técnicos**: RSI, Bollinger, MACD...
5. **StandardScaler** — ajustado solo en train.
6. **Triple-barrier labeling** ($\tau > 0,98$).



Barras de volumen: Muestreo adaptativo

Barras de tiempo (1 min)

- × Muestreo uniforme en el tiempo.
- × Saturación en baja actividad de mercado.


✓ Barras de volumen (50k uBTC)

- Proporcional a la actividad real.
- Menor autocorrelación y heterocedasticidad.
- Mayor resolución en períodos volátiles.



Bot de trading: Arquitectura

- ⚙️ **Orquestador:** instancia módulos.
- 🤖 **Motor:** recolectar → predecir → actuar.
- 💾 **Exchange:** API Binance real o mock.
- 📈 **Estrategia:** Modelo configurado → señal.



señal

Stop-loss · monitoreo Flask.
Desplegado en Binance (producción).

4. Experimentos y resultados

Algoritmos de trading clásicos

Clasificador	F1	Std
BollingerBands	0,511	0,022
RSIDivergence	0,508	0,001
MaCrossover	0,501	0,002
MACD	0,499	0,002
SmaCross	0,498	0,002

✗ Ninguno supera $F1 = 0,51$.

✓ RSIDivergence: std = 0,001 — más confiable.

⚠ BollingerBands: mayor techo, mayor riesgo.

🔍 6 clasificadores · 184 trials.

El análisis técnico simple no captura señal.

Modelos estadísticos: ARIMA, GARCH, Kalman

Modelo	F1 máx	Std
ARIMA	0,500	0,118
ARIMA-GARCH	0,495	0,116
SARIMA	0,486	0,046
Kalman-ARIMA	0,418	0,165

✗ Ninguno supera el azar.

↓ Más complejidad = peor resultado.

⚠ Std 0,118 → fallas catastróficas (F1 → 0).

🔑 **threshold** $\approx 10^{-6}$, corr = -0,93.

PBO = 0: consistentemente al nivel del azar.

Machine Learning: XGBoost y AutoGluon

Algoritmo	F1 máx	n
XGBoost Palazzo	0,647	60
AutoGluon Palazzo	0,639	20

**max_depth=4 · lr=0,003 ·
n_est=373**

Mejor

AutoGluon:

LightGBMXT_BAG_L1

↑ F1: 0,50 → 0,65 — primer salto real.

⌚ AutoGluon: misma calidad, 10× más lento.

⊖ PCA no aporta en ningún trial.

✓ $\tau > 0,98$: etiquetas menos frecuentes, más limpias.

PBO = 0,486 — selección moderada.


Transformer: 3 familias Chronos

Familia	Pipeline	F1 máx	Std
Embeddings	ChronosFeature T5-small	0,633	0,022
Embeddings	ChronosBoltFeature	0,628	0,008
Meta-etiquetado	ChronosMetaLabeling	0,657	—
Fine-tuning	FinetuneToClass (Chronos-2)	0,819	—

Meta-filtro: degrada el F1 en 6 de 8 runs.

Fine-tuning end-to-end: **+0,16 F1** sobre embeddings.

Resumen: 4 familias de modelos



0,819
F1 OOS — Transformer

+0,16
Brecha vs. 2º mejor

Mismo framework · mismos
datos · misma métrica.

Selección del modelo: CSCV cruzado

Experimento	IS	OOS
FinetuneToClass	98,6 %	98,6 %
Finetuned_Feature	1,4 %	1,4 %
Resto (5 exp.)	0 %	0 %

$N=203$ trials, $C=70$ combinaciones, PBO
= 0.

0,819

F1 OOS — modelo final

chronos-2-small

$\tau = 0,910$

volume_threshold = 45 988

Validación final: CPCV (5 caminos disjuntos)

Camino	F1
1	0,8219
2	0,8235
3	0,8221
4	0,8303
5	0,8277
Media	$0,825 \pm 0,003$

- ✓ Std = 0,003 — rendimiento estable.
- ✓ Caminos 4 y 5 (más recientes) no caen.
- ✓ F1 CPCV (0,825) > F1 Optuna (0,818).
- ✓ 17 330 predicciones OOS totales.

$0,825 \pm 0,003$


F1 medio CPCV — sin sobreajuste

5. Conclusiones

Conclusiones y próximos pasos

✓ Logros

- Pipeline completo: 3M+ filas BTC/USDT.
- ARIMA y trading clásico: nivel del azar.
- XGBoost: primer salto real ($F1 = 0,65$).
- Chronos fine-tuning: $F1 = 0,819$, validado.
- Bot operativo con stop-loss automático.



➔ **Próximos pasos:** Bet sizing · Ensamble · HRP · Microestructura.

Demostración: Bot en producción

Bot operativo en Binance

https://drive.google.com/file/d/1ybZkajjzUriHRqoBw0tH0f-fCc4mB_6i/view?usp=sharing



Datos Binance
en tiempo real.



Señal Chronos
BTC ↔ USDT.



Monitoreo Flask
+ stop-loss.

¡Gracias!

Ing. Martín Leonardo Centurión

centurionm.leo@gmail.com

¿Preguntas?

Parte I

Apéndice

Respaldo: Hiperparámetros XGBoost Palazzo

Parámetro	Valor
max_depth	4
learning_rate	0,00328
n_estimators	373
tau	1,261
volume_threshold	28 522
use_pca	False

Respaldo: Hiperparámetros modelo final Chronos

Parámetro	Valor
Modelo base	autogluon/chronos-2-small
τ	0,910
volume_threshold	45 988
prediction_length	2
pct_embargo	0,05
n_splits	3

Respaldo: Sensibilidad modelos estadísticos

Modelo	Parámetro	Corr	Interpretación
ARIMA-family	threshold	-0,93	Umbral cercano a cero es crítico
ARIMAXGARCH	threshold	-0,99	Umbrales altos degradan el modelo
ARIMAClassifier	lookback	-0,37	Historial corto (720 h) preferido
ARIMAXGARCH	q (MA)	+0,85	Orden MA alto es mejor

Respaldo: Barras de volumen vs. barras temporales

Barras de tiempo (1 min)

- Muestreo uniforme en el tiempo.
- Alta autocorrelación en baja actividad.

Barras de volumen (50 000 uBTC)

- Muestreo por actividad real.
- Menor autocorrelación y heterocedasticidad.
- Mayor resolución en alta volatilidad.



Respaldo: Diferenciación fraccional

- $d = 1$: serie de retornos — elimina demasiada memoria.
- $d = 0$: precio original — no estacionario.
- $d \approx 0,4$: mínimo que garantiza estacionariedad (ADF 95 %).

$$d = 0,4$$

Punto óptimo entre
memoria e información.

Preserva la mayor cantidad de contexto
histórico posible sin violar estacionariedad.